

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG

LÊ BÁ PHÚC

22521115-ATTT2022.2

BÁO CÁO THỰC TẬP DOANH NGHIỆP

**DFD-IDS: Decentralized Federated Distillation for Heterogeneous
and Poisoning-Resilient Intrusion Detection via Energy-Aware Robust
Logit Fusion**

TP. HỒ CHÍ MINH, THÁNG 6/2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA MẠNG MÁY TÍNH VÀ TRUYỀN THÔNG

BÁO CÁO THỰC TẬP DOANH NGHIỆP

**DFD-IDS: Decentralized Federated Distillation for Heterogeneous
and Poisoning-Resilient Intrusion Detection via Energy-Aware Robust Logit Fusion**

Trung tâm An ninh mạng

ThS. Nguyễn Hữu Quyền

Lê Bá Phúc

22521115-ATTT2022.2

TP. HỒ CHÍ MINH, THÁNG 6/2026

PHIẾU XÁC NHẬN THỰC TẬP

Công ty:.....**xác nhận:**

Anh/chị: Sinh ngày:

Sinh viên năm thứ.....Khoa:Trường:

Đã thực tập tại:

Thời gian thực tập:.....

Vị trí thực tập:.....

Nhiệm vụ được giao và hướng dẫn:.....

.....

Cán bộ phụ trách và hướng dẫn:

Chức vụ:.....

Đánh giá quá trình thực tập của sinh viên:

Các kết quả sinh viên đã thực hiện được: ...

.....

Các tiêu chí đánh giá	Điểm đánh giá (Theo thang điểm 10)	Ghi chú
1. Năng lực chuyên môn		
2. Chất lượng công việc		
3. Tinh thần trách nhiệm		
4. Tính chủ động sáng tạo		
5. Tính kỷ luật		
6.		
Tổng điểm:		

Đánh giá khác:

.....

..., ngày...tháng ...năm ...

TRƯỞNG ĐƠN VỊ

NHÂN SỰ

CÁN BỘ QUẢN LÝ TRỰC TIẾP

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

Họ và tên sinh viên:

MSSV:

Công ty thực tập:

Thời gian thực tập:.....

Vị trí thực tập:.....

Nhiệm vụ được giao:

.....

.....

Đánh giá quá trình thực tập của sinh viên:

Các kết quả sinh viên đã thực hiện được:

.....

.....

.....

.....

.....

.....

Điểm:Bằng chữ:.....

....., ngày.....thángnăm

Giáo viên hướng dẫn

Lời cảm ơn

Em xin bày tỏ lòng biết ơn sâu sắc đến quý thầy cô Khoa Mạng máy tính và Truyền thông, Trường Đại học Công nghệ Thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh, những người đã truyền đạt nền tảng kiến thức chuyên môn, phương pháp tư duy khoa học và tinh thần làm việc nghiêm túc trong suốt quá trình học tập. Những bài giảng, những buổi thảo luận và những góp ý học thuật đã tạo nên cơ sở vững chắc để đề tài này được hình thành và phát triển theo hướng bài bản, có hệ thống và phù hợp với định hướng nghiên cứu của ngành.

Đặc biệt, em xin trân trọng cảm ơn ThS. Nguyễn Hữu Quyền, giảng viên hướng dẫn của báo cáo thực tập. Trong suốt quá trình thực hiện đề tài, từ giai đoạn xác định vấn đề nghiên cứu, xây dựng cơ sở lý thuyết, thiết kế hệ thống cho đến triển khai thực nghiệm và hoàn thiện bản thảo, sự hướng dẫn tận tình và những góp ý chi tiết của thầy đã giúp em nhìn nhận vấn đề một cách chặt chẽ và toàn diện hơn. Những buổi trao đổi chuyên môn không chỉ dừng lại ở việc chỉnh sửa nội dung, mà còn định hình phương pháp tiếp cận khoa học, cách tổ chức lập luận và cách trình bày kết quả một cách mạch lạc. Sự nghiêm túc trong học thuật và tinh thần trách nhiệm của thầy là nguồn động lực quan trọng để báo cáo này được hoàn thiện với chất lượng tốt nhất trong khả năng của em.

Bên cạnh đó, em xin gửi lời cảm ơn đến tập thể cán bộ, giảng viên và nhân viên của Khoa đã tạo điều kiện thuận lợi về cơ sở vật chất, tài liệu tham khảo và môi trường học tập.

Em cũng xin trân trọng cảm ơn Trung tâm An ninh mạng đã tạo điều kiện thực tập, cung cấp môi trường làm việc chuyên nghiệp, cơ sở hạ tầng kỹ thuật và những bài toán thực tế có giá trị, giúp em áp dụng kiến thức học thuật vào thực tiễn một cách hiệu quả.

Cuối cùng, mặc dù vẫn còn một số hạn chế và nhiều hướng có thể tiếp tục cải thiện, báo cáo đã đạt được các mục tiêu đề ra và cung cấp những kết quả ban đầu khả quan cho bài toán nghiên cứu. Những góp ý và nhận xét từ quý thầy cô sẽ là cơ sở quan trọng để tác giả tiếp tục hoàn thiện và phát triển hướng nghiên cứu này trong tương lai.

TP. Hồ Chí Minh, tháng 06 năm 2026

Mục lục

Danh sách hình vẽ

Danh sách bảng biểu

Danh mục từ viết tắt

Viết tắt	Tiếng Anh	Tiếng Việt
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
DL	Deep Learning	Học sâu
DFL	Decentralized Federated Learning	Học liên kết phân tán
DDoS	Distributed Denial of Service	Từ chối dịch vụ phân tán
EKD	Evidential Knowledge Distillation	Chắt lọc kiến thức dựa trên bằng chứng
EVA	Energy-based Abstention	Cơ chế bỏ phiếu trắng dựa trên năng lượng
FD	Federated Distillation	Chắt lọc kiến thức liên kết
FL	Federated Learning	Học liên kết
GNN	Graph Neural Network	Mạng nơ-ron đồ thị
GRU	Gated Recurrent Unit	Bộ nhớ hồi tiếp có cổng
IDS	Intrusion Detection System	Hệ thống phát hiện xâm nhập
IoT	Internet of Things	Internet vạn vật
LMA	Loss Maximization Attack	Tấn công tối đa hóa mất mát
ML	Machine Learning	Học máy

CHƯƠNG 1

Tổng quan

1.1 Giới thiệu về Trung tâm An ninh mạng

Trung tâm An ninh mạng (Cyber Security Center) là đơn vị hoạt động trong lĩnh vực bảo mật thông tin và an toàn mạng, cung cấp các giải pháp phát hiện, ngăn chặn và ứng phó với các mối đe dọa mạng. Với đội ngũ chuyên gia giàu kinh nghiệm và hệ thống cơ sở hạ tầng kỹ thuật hiện đại, Trung tâm hướng đến việc nghiên cứu và phát triển các công nghệ tiên tiến trong lĩnh vực an ninh mạng, bao gồm hệ thống phát hiện xâm nhập (IDS), phân tích mã độc, săn tìm mối đe dọa (threat hunting) và ứng dụng trí tuệ nhân tạo trong bảo mật.

Các lĩnh vực hoạt động chính của Trung tâm bao gồm:

- Nghiên cứu và phát triển các giải pháp an ninh mạng tiên tiến dựa trên trí tuệ nhân tạo và học máy.
- Xây dựng hệ thống giám sát an ninh mạng (SOC) và quy trình ứng phó sự cố.
- Phân tích mã độc và điều tra số (digital forensics).
- Đánh giá bảo mật hệ thống (penetration testing, vulnerability assessment).
- Đào tạo và nâng cao nhận thức về an ninh mạng cho tổ chức và cá nhân.
- Hợp tác nghiên cứu với các trường đại học, viện nghiên cứu trong và ngoài nước.

Môi trường thực tập tại Trung tâm tạo điều kiện cho sinh viên tiếp cận với các bài toán thực tế, hệ thống hạ tầng mạng quy mô lớn và những thách thức bảo mật đang nổi lên trong bối cảnh chuyển đổi số. Trong thời gian thực tập, nhóm tác giả đã được tham gia vào quá trình nghiên cứu và phát triển hệ thống phát hiện xâm nhập dựa trên học liên kết, một hướng tiếp cận mới nhằm giải quyết các vấn đề về quyền riêng tư dữ liệu, tính không đồng nhất của môi trường mạng và khả năng chống chịu trước các cuộc tấn công độc hại.

Quy trình thực tập tại Trung tâm được tổ chức theo các giai đoạn: (i) định hướng và làm quen với môi trường làm việc, (ii) nghiên cứu lý thuyết và tìm hiểu công nghệ nền

tăng, (iii) thiết kế và phát triển giải pháp, (iv) thực nghiệm và đánh giá kết quả, (v) hoàn thiện báo cáo và trình bày kết quả. Trong suốt quá trình thực tập, nhóm tác giả được sự hướng dẫn trực tiếp từ các chuyên gia và cán bộ kỹ thuật của Trung tâm, đảm bảo định hướng nghiên cứu phù hợp với nhu cầu thực tế và xu hướng công nghệ mới nhất.

1.2 Lý do chọn đề tài

Hệ thống phát hiện xâm nhập (Intrusion Detection Systems – IDS) là một thành phần quan trọng trong hạ tầng an ninh mạng hiện đại, cho phép xác định các hoạt động độc hại trong các mạng doanh nghiệp, đám mây, công nghiệp và Internet vạn vật (IoT). Các báo cáo gần đây cho thấy các cuộc tấn công nhắm vào IoT tiếp tục gia tăng [?], trong khi các hệ thống bảo vệ nhà thông minh chặn hàng triệu sự kiện độc hại mỗi ngày [?]. Các mối đe dọa này bao gồm từ lây nhiễm mã độc, tuyển dụng botnet đến các chiến dịch tấn công từ chối dịch vụ phân tán (DDoS) quy mô lớn [?], làm nổi bật nhu cầu về các hệ thống phát hiện xâm nhập hiệu quả và có khả năng mở rộng.

Do đó, những tiến bộ gần đây trong Học máy (Machine Learning – ML) và Học sâu (Deep Learning – DL) đã cải thiện đáng kể khả năng phát hiện của IDS thông qua việc tự động học các mẫu lưu lượng phức tạp từ dữ liệu mạng quy mô lớn. Tuy nhiên, việc huấn luyện hiệu quả các IDS dựa trên ML thường yêu cầu thu thập dấu vết lưu lượng từ nhiều tổ chức, gây ra các vấn đề về quyền riêng tư, bảo mật và tuân thủ quy định. Học liên kết (Federated Learning – FL) [?] đã nổi lên như một mô hình đầy hứa hẹn cho phép huấn luyện IDS cộng tác mà không chia sẻ trực tiếp dữ liệu lưu lượng riêng tư.

Mặc dù thiết kế của FL cải thiện rõ rệt tính bảo mật dữ liệu của các bên tham gia, việc triển khai thực tế FL-based IDS vẫn còn nhiều thách thức. Các mạng nơ-ron sâu hiện đại thường chứa hàng triệu tham số, dẫn đến chi phí truyền thông đáng kể trong quá trình trao đổi tham số lặp đi lặp lại. Hơn nữa, các nghiên cứu gần đây đã chỉ ra rằng các bản cập nhật mô hình có thể làm rò rỉ thông tin huấn luyện nhạy cảm thông qua các cuộc tấn công gradient inversion và reconstruction. Mặc dù tồn tại nhiều giải pháp cho vấn đề này như Secure Aggregation [?] và Homomorphic Encryption [?], những kỹ thuật này lại tạo ra chi phí tính toán và truyền thông đáng kể do ứng dụng các bước mã hóa lên trọng số mô hình.

Để giảm việc truyền tham số và hạn chế rủi ro lộ thông tin từ các bản cập nhật mô hình, các nghiên cứu gần đây đã ứng dụng kỹ thuật chắt lọc kiến thức (Knowledge Distillation) [?] vào học máy liên kết, mở ra một lĩnh vực nghiên cứu học chắt lọc liên kết (Federated Distillation – FD) [?]. Thay vì trao đổi tham số mô hình, các phần tử client trong hệ thống FD trao đổi các biểu diễn tri thức trung gian như logits hoặc prototypes. Điều này cho phép các hệ thống FD điều chỉnh chi phí truyền thông đồng thời hỗ trợ liên kết giữa các kiến trúc mô hình không đồng nhất (model heterogeneity). Nhờ đó, FD đã trở thành một giải pháp thay thế hấp dẫn cho các môi trường hạn chế tài nguyên và không đồng nhất,

đặc biệt là các thiết bị biên (edge devices), thiết bị nhúng (IoT) và nút mạng.

Tuy nhiên, hầu hết các giải pháp FD hiện tại vẫn phụ thuộc vào một máy chủ tổng hợp tập trung. Trong các triển khai quy mô lớn, sự ổn định của hệ thống học liên kết phải phụ thuộc vào đúng một phần tử duy nhất là máy chủ. Nếu máy chủ này gặp sự cố do tấn công hoặc lỗi hạ tầng, toàn bộ quá trình học liên kết bị buộc phải ngừng trệ. Do đó, học liên kết phân tán (Decentralized Federated Learning – DFL) giải quyết hạn chế này bằng cách phân phối trách nhiệm điều phối giữa các clients tham gia và loại bỏ sự phụ thuộc vào máy chủ vĩnh viễn [?].

Ngoài các vấn đề về băng thông truyền tải và điều phối quy trình học liên kết, các hệ thống liên kết vẫn dễ bị tổn thương trước các tác nhân Byzantine cố tình đầu độc dữ liệu cục bộ (data poisoning), đầu độc cập nhật mô hình (model poisoning) hoặc đầu độc biểu diễn trung gian (logit poisoning) [?, ?, ?]. Các cuộc tấn công gần đây đã tiến hóa từ việc tạo ra các giá trị cực đại để phát hiện đến việc tạo ra các bản cập nhật độc hại gần giống với hành vi bất thường trong ngữ cảnh bất đồng dữ liệu Non-IID, khiến việc phát hiện ngày càng khó khăn [?]. Các phương pháp phòng thủ tấn công Byzantine hiện có hầu hết tập trung vào FL trong không gian tham số, trong khi các phương pháp phòng thủ có thể ứng dụng cho không gian biểu diễn (như logit) cho các hệ thống FD vẫn còn tương đối mới và ít được nghiên cứu hơn.

Trong giai đoạn thực tập, em và thành viên trong nhóm nghiên cứu đã xây dựng, thực nghiệm và đề xuất DFD-IDS, một cơ chế chất lọc kiến thức liên kết phân tán có khả năng chống chịu đầu độc Byzantine, với cơ chế tổng hợp logits dựa trên energy. DFD-IDS kết hợp Chất lọc kiến thức dựa trên bằng chứng (Evidential Knowledge Distillation – EKD) để bảo toàn độ bất định trong phân phối dự đoán của mô hình, kỹ thuật tiết chế đóng góp dựa trên energy (Energy-based Vote Abstention – EVA) để lọc các dự đoán mẫu công khai thiếu tự tin, cơ chế lọc kết hợp RobustFilter [?] và ước lượng xác suất phân phối chuẩn của Blom [?] mới có khả năng chống chịu Byzantine hiệu quả cao. Thêm vào đó, thiết kế lựa chọn phần tử điều phối cho môi trường phân tán được thực hiện dựa trên điểm số lọc của từng client. Bằng cách kết hợp các thành phần này, giải pháp đề xuất cho phép chia sẻ tri thức hiệu quả giữa các clients không đồng nhất về cả kiến trúc mô hình và phân bố dữ liệu, đồng thời duy trì khả năng chống chịu trước các cuộc tấn công đầu độc Byzantine trong môi trường phân tán.

Các đóng góp chính của đề tài bao gồm:

- Đề xuất DFD-IDS, một hệ thống học chất lọc kiến thức liên kết phi tập trung cho phát hiện xâm nhập phân tán có khả năng phòng chống tấn công Byzantine.
- Giới thiệu cơ chế Energy-based Vote Abstention (EVA) giúp thích ứng phát hiện ngoài phân phối dựa trên năng lượng vào việc chọn lọc dự đoán mẫu công khai trong môi trường liên kết, mà không cần lệ thuộc trên một mô hình phụ để phân biệt.
- Phát triển Bộ lọc Blom Robust Filter giúp quá trình tổng hợp logits chống được

tấn công Byzantine trong môi trường clients không đồng nhất.

- Đánh giá DFD-IDS trước các kỹ thuật tấn công Byzantine hiện đại và chứng minh khả năng chống chịu vượt trội so với các phương pháp cơ sở hiện có.

1.3 Mục tiêu, đối tượng và phạm vi

1.3.1 Mục tiêu nghiên cứu

Mục tiêu chính của đề tài là nghiên cứu, thiết kế và hiện thực một hệ thống phát hiện xâm nhập mạng dựa trên học liên kết chất lọc có khả năng phân tán, chống chịu trước các tấn công đầu độc (poisoning attacks) và hỗ trợ kiến trúc mô hình không đồng nhất (heterogeneous architectures). Cụ thể:

- Nghiên cứu tổng quan về các hệ thống IDS dựa trên học máy và học liên kết.
- Tìm hiểu các phương pháp Federated Distillation và khả năng ứng dụng trong bảo mật mạng.
- Phân tích các dạng tấn công đầu độc hại trong học liên kết và cơ chế phòng thủ tương ứng.
- Đề xuất và hiện thực khung giải pháp DFD-IDS với các thành phần chống chịu Byzantine.
- Đánh giá hiệu quả của giải pháp thông qua các kịch bản thực nghiệm.

1.3.2 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm:

- Hệ thống phát hiện xâm nhập mạng (Network-based IDS).
- Học liên kết tập trung và phân tán (Centralized & Decentralized Federated Learning).
- Các phương pháp chất lọc kiến thức liên kết (Federated Distillation).
- Các kỹ thuật phát hiện và chống chịu tấn công đầu độc hại trong môi trường liên kết.
- Mô hình học sâu (Deep Neural Networks, GRU, CNN) cho dữ liệu mạng.

1.3.3 Phạm vi nghiên cứu

Đề tài tập trung vào:

- Dữ liệu mạng từ các bộ dữ liệu chuẩn như CSE-CIC-IDS2018 và các tập dữ liệu liên quan.
- Môi trường thực nghiệm trong phòng lab với các máy chủ được cấu hình phù hợp.
- Đánh giá trên các chỉ số: Accuracy, Macro precision, Macro recall, Macro F1-Score và khả năng chống chịu tấn công.

1.4 Những điểm mới của đề tài

Đề tài nghiên cứu có những điểm mới sau đây so với các công trình hiện có:

1. **Kiến trúc phân tán hoàn toàn:** Không giống như các phương pháp FL-IDS hiện tại chủ yếu dựa trên server trung tâm, DFD-IDS loại bỏ hoàn toàn sự phụ thuộc vào một máy chủ trung tâm thông qua cơ chế chọn phần tử điều phối từ kết quả tổng hợp logit. Điều này giúp loại bỏ lệ thuộc vào một phần tử duy nhất, qua đó cải thiện tính ổn định hệ thống trong vận hành thực tế.
2. **Energy-based Vote Abstention (EVA):** Đề xuất áp dụng cơ chế phát hiện out-of-distribution dựa trên năng lượng (Energy-based OOD) vào bài toán chọn lọc dự đoán nhãn công khai trong Federated Distillation. EVA tiết kiệm chi phí hơn nhiều so với phương pháp dựa vào mô hình phụ của SSFL-IDS và không yêu cầu tạo sinh một bộ dữ liệu riêng cho mô hình này.
3. **Blom Robust Filter:** Đề xuất một phương pháp tổng hợp mới dựa trên xác suất phân phối Blom, khắc phục hạn chế từ phương pháp RobustFilter phải lệ thuộc vào một ngưỡng cố định như đã ứng dụng trong Cronus [?]. Phương pháp này có khả năng thích ứng với số lượng clients và số chiều logits khác nhau.
4. **Kết hợp EKD và FL:** Ứng dụng kỹ thuật chất lọc hiện đại là Evidential Knowledge Distillation để cho phép các kiến trúc mô hình khác nhau tham gia học liên kết.

1.5 Phương pháp nghiên cứu

Phương pháp nghiên cứu được áp dụng trong đề tài bao gồm:

- **Nghiên cứu lý thuyết:** Thu thập, phân tích và tổng hợp các tài liệu khoa học liên quan đến IDS, Federated Learning, Federated Distillation, Byzantine-robust aggregation và các lĩnh vực liên quan.

- Nghiên cứu thực nghiệm: Thiết kế và hiện thực các mô hình, tiến hành thực nghiệm trên các bộ dữ liệu chuẩn, so sánh kết quả với các phương pháp nền tảng.
- **Đánh giá định lượng:** Sử dụng các chỉ số đánh giá khách quan để đo lường hiệu suất của hệ thống.
- **Phân tích so sánh:** So sánh phương pháp đề xuất với các phương pháp hiện có (FedAvg, FedProto, FLAME, SSFL-IDS và FedKD-IDS) trên cùng điều kiện thực nghiệm.

1.6 Kế hoạch thực tập chi tiết

Quá trình thực tập tại Trung tâm An ninh mạng được chia thành 8 tuần với các mục tiêu cụ thể cho từng giai đoạn. Bảng ?? tóm tắt kế hoạch thực tập tổng thể.

Bảng 1.1: Kế hoạch thực tập tổng thể

Giai đoạn	Tuần	Mục tiêu
Định hướng	1-2	Làm quen môi trường, nghiên cứu tổng quan
Nghiên cứu lý thuyết	3-4	Tìm hiểu FL, FD, Byzantine attacks, defenses
Phát triển giải pháp	5-6	Thiết kế và hiện thực DFD-IDS
Thực nghiệm & Đánh giá	7	Tiến hành thực nghiệm, thu thập kết quả
Hoàn thiện	8	Phân tích kết quả, viết báo cáo

1.7 Cấu trúc báo cáo

Báo cáo thực tập được tổ chức thành 5 chương:

- **Chương 1 – Tổng quan:** Giới thiệu về Trung tâm An ninh mạng, bối cảnh nghiên cứu, lý do chọn đề tài, mục tiêu, đối tượng, phạm vi và phương pháp nghiên cứu.
- **Chương 2 – Cơ sở lý thuyết:** Trình bày các kiến thức nền tảng hệ thống IDS, học máy liên kết, chất lọc kiến thức, học chất lọc liên kết, tấn công Byzantine và các kỹ thuật phòng thủ tương ứng.
- **Chương 3 – Phương pháp thực hiện:** Mô tả chi tiết khung giải pháp DFD-IDS được đề xuất, bao gồm kiến trúc tổng thể, cơ chế Energy-based Vote Abstention, Blom Robust Filter, cơ chế chọn server phân tán và Evidential Knowledge Distillation.

- **Chương 4 – Thực nghiệm và đánh giá:** Trình bày môi trường thực nghiệm, tập dữ liệu, các kịch bản thử nghiệm, kết quả đạt được và bảng so sánh với các phương pháp khác.
- **Chương 5 – Kết luận và hướng phát triển:** Tổng kết các kết quả đạt được, đánh giá ưu nhược điểm của giải pháp và đề xuất các hướng phát triển trong tương lai.

CHƯƠNG 2

Cơ sở lý thuyết

2.1 Hệ thống IDS

Hệ thống phát hiện xâm nhập (IDS) là một thành phần quan trọng trong hạ tầng an ninh mạng hiện đại, cho phép xác định các hoạt động độc hại trong các mạng doanh nghiệp, đám mây, công nghiệp và IoT. Như đã trình bày trong Mục ??, bối cảnh mới đe dọa tiếp tục phát triển với các cuộc tấn công ngày càng tinh vi.

2.1.1 Phân loại IDS

IDS có thể được phân loại theo nhiều tiêu chí khác nhau:

Theo phương pháp phát hiện:

- **Signature-based IDS:** Phát hiện dựa trên các mẫu tấn công đã biết (chữ ký). Hiệu quả cao với các tấn công cũ nhưng không phát hiện được tấn công mới (zero-day).
- **Anomaly-based IDS:** Phát hiện dựa trên sự khác biệt so với hành vi bình thường của hệ thống. Có thể phát hiện tấn công mới nhưng tỷ lệ dương tính giả cao.

Theo nguồn dữ liệu:

- **Network-based IDS (NIDS):** Phân tích lưu lượng mạng để phát hiện tấn công.
- **Host-based IDS (HIDS):** Giám sát hoạt động trên một máy chủ cụ thể, bao gồm log hệ thống, tiến trình và tệp tin.

2.1.2 IDS dựa trên học sâu

Những tiến bộ gần đây trong ML và DL đã cải thiện đáng kể khả năng phát hiện của IDS thông qua việc tự động học các mẫu lưu lượng phức tạp từ dữ liệu mạng quy mô lớn. Khi xem xét IDS như một bài toán phân loại, vậy thì ta cần một mô hình có khả năng phân loại các kiểu lưu lượng mạng, với đầu vào là các đặc trưng của gói tin như header, IAT, flag... và đầu ra là số kiểu dữ liệu cần phân loại.

Mạng CNN trong phát hiện xâm nhập

Convolutional Neural Networks (CNN) có khả năng tự động học các đặc trưng không gian từ dữ liệu thô thông qua các lớp tích chập (convolutional layers). Trong bài toán IDS, lưu lượng mạng có thể được biểu diễn dưới dạng ma trận 2 chiều (ví dụ: $\text{time} \times \text{features}$) và CNN có thể học các mẫu tấn công cục bộ trong không gian đặc trưng này. Các nghiên cứu gần đây cho thấy CNN đạt hiệu quả cao trong việc phân loại lưu lượng mạng và phát hiện các cuộc tấn công khác nhau.

Mạng GRU trong phát hiện xâm nhập

Gated Recurrent Units (GRU) là một biến thể của mạng nơ-ron hồi tiếp (RNN), được thiết kế để giải quyết vấn đề vanishing gradient thông qua cơ chế cổng (gate mechanism). Trong bối cảnh IDS, GRU có khả năng mô hình hóa các phụ thuộc thời gian trong chuỗi các gói tin mạng, cho phép phát hiện các hành vi tấn công có tính chất tuần tự như port scanning và brute force.

Thách thức trong triển khai

Thách thức chính trong việc triển khai IDS dựa trên học máy tập trung là yêu cầu về lượng lớn dữ liệu huấn luyện được gán nhãn từ các bên tham gia, điều thường khó đạt được trong thực tế do các ràng buộc về quyền riêng tư và quy định. Ngoài ra, các mẫu lưu lượng mạng thay đổi theo thời gian, đòi hỏi các vòng trao đổi dữ liệu phải diễn ra liên tục. Chi phí tính toán để huấn luyện các mô hình học sâu cũng là một vấn đề đối với các môi trường hạn chế tài nguyên. Những thách thức này thúc đẩy việc áp dụng Học liên kết (Federated Learning), cho phép huấn luyện mô hình cộng tác trong khi vẫn bảo vệ quyền riêng tư dữ liệu.

2.2 Học liên kết (Federated Learning)

2.2.1 Học liên kết tập trung (Centralized Federated Learning)

Trong Học liên kết tập trung (Centralized FL), một máy chủ khởi tạo và duy trì một mô hình toàn cục trong khi các clients phân tán cùng tối ưu hóa mô hình này bằng dữ liệu riêng của họ. Khung giải pháp được công nhận rộng rãi nhất trong bối cảnh này là FedAvg [?]. Trong FedAvg, mô hình toàn cục f^0 được khởi tạo bởi máy chủ và gửi đến tất cả clients trong tập K . Với mỗi vòng liên kết t , các clients đồng thời tối ưu hóa các tham số w^t của f^t sử dụng tập dữ liệu riêng $D_k, k \in K$, $w_k^t \leftarrow \text{ClientUpdate}(k, w_t)$ trước khi truyền các tham số mô hình cục bộ w_k^t đến máy chủ. Máy chủ sau đó thực hiện tổng hợp có trọng số

trên tập các tham số client để tính toán tham số mô hình toàn cục cho vòng tiếp theo w^{t+1} theo Phương trình ??.

$$w^{t+1} = \sum_{k \in K} \frac{|D_k|}{|D|} w_k^t \quad (2.1)$$

trong đó D_k là tập dữ liệu cục bộ của client k , $|D_k|$ là kích thước của nó, và $|D|$ là tổng kích thước mẫu của tất cả clients tham gia trong vòng liên kết hiện tại t . Máy chủ gửi mô hình toàn cục đã tính toán đến tất cả clients và lặp lại sang vòng tiếp theo.

Trong bối cảnh phát hiện xâm nhập, mỗi client quan sát các khối lượng mẫu tấn công khác nhau; do đó, sự phân phối dữ liệu không đồng nhất cả về số lượng và lớp phân loại là một thách thức cố hữu đối với học liên kết. Điều kiện này, được biết đến rộng rãi với tên gọi dữ liệu không độc lập và đồng nhất (Non-IID), gây ra hiện tượng “client drift” [?]. Với dữ liệu Non-IID, mục tiêu tối ưu hóa cục bộ của mỗi client không thể tương thích với mục tiêu toàn cục do sự thiên lệch cục bộ của tập dữ liệu riêng ở mỗi phần tử client [?], làm chậm tốc độ hội tụ và giảm hiệu suất mô hình toàn cục.

Để giải quyết thách thức Non-IID, nhiều thuật toán FL đã được đề xuất bao gồm các phương pháp thường biết đến nhất như FedProx [?], FedMLB [?] và FedDyn [?]. Các phương pháp này điều chỉnh mục tiêu tối ưu hóa cục bộ để hạn chế client drift, cải thiện hiệu quả của học liên kết trong môi trường Non-IID.

Mặc dù có khả năng chống chịu cao với điều kiện Non-IID, FL tập trung yêu cầu các client truyền tham số mô hình, gây ra những hạn chế nghiêm trọng trong triển khai thực tế. Các nghiên cứu gần đây như Deep Leakage from Gradients (DLG) [?] và improved Deep Leakage from Gradients (iDLG) [?] đã thành công trong việc tái tạo mẫu huấn luyện từ gradient với độ chính xác đáng báo động, trong khi [?] đề xuất một cuộc tấn công tái tạo mạnh hơn thiết kế trực tiếp cho môi trường FL, cho thấy rằng các tham số mô hình không còn bảo đảm quyền riêng tư trước một máy chủ không đáng tin. Ngoài tấn công đảo ngược mô hình, nhiều công trình đề xuất tấn công suy diễn [?, ?, ?] trên các tham số mô hình, khai thác được các thông tin cá nhân nhạy cảm của từng phần tử tham gia.

Nhiều công trình đã tìm cách giải quyết điểm yếu này: SecureAggregation [?] và DeepFed [?] là các biến thể bảo vệ quyền riêng tư dựa trên các kỹ thuật mã hóa như Diffie-Hellman masking hoặc mã hóa đồng cấu Paillier. Tuy nhiên, các phương pháp này yêu cầu chi phí tính toán cao đáng kể và các hạn chế trong môi trường production. Ví dụ, SecureAggregation tạo thêm các vòng truyền thông và cơ chế phục hồi dropout, làm tăng độ phức tạp giao thức trong triển khai quy mô lớn. Tương tự, các phương pháp dựa trên mã hóa đồng cấu như DeepFed tạo ra chi phí tính toán cao và lệ thuộc vào việc quản lý khóa giải mã.

2.2.2 Chất lọc kiến thức liên kết tập trung (Centralized Federated Distillation)

Chất lọc kiến thức liên kết (Federated Distillation – FD) [?, ?, ?] nổi lên như một biến thể của Học liên kết kết hợp FL với Chất lọc kiến thức (Knowledge Distillation) [?]. Các giải pháp FD, bao gồm FedMD [?] và FederatedDistillation [?] truyền tải các biểu diễn tri thức trung gian như logits hoặc class prototypes [?] thay vì tham số mô hình.

FederatedDistillation tính toán vector logit trung bình đã kích hoạt softmax $\bar{p}_{c,k}$ của mỗi lớp c trong tập dữ liệu riêng D_k của mỗi client k , $\bar{p}_{c,k} \leftarrow \frac{1}{|c|} \sum_{x \in D_k, y|x=c} p(x)$. Sau đó, máy chủ tính tổng các vector logit của tất cả clients cho mỗi lớp $c \in C$, $\bar{p}_c \leftarrow \sum_{k \in K} \bar{p}_{c,k}$. Với mỗi lớp, mỗi client trừ vector trung bình của chính nó khỏi vector toàn cục để thu được vector trung bình leave-one-out $\hat{p}_{c,k} \leftarrow \frac{1}{|K|-1}(\bar{p}_c - \bar{p}_{c,k})$. Mỗi client tối ưu hóa mô hình cục bộ qua Phương trình ?? cho mỗi mẫu x trong tập dữ liệu riêng:

$$w_k \leftarrow w_k - \eta \nabla \{ \phi(p(x), y_i) + \gamma \cdot \phi(p(x), \hat{p}_{c,k}) \} \quad (2.2)$$

trong đó ϕ là hàm mất mát cross-entropy, γ là siêu tham số điều khiển cường độ chất lọc.

Các khung giải pháp FD gần đây đã phát triển để hoạt động trên một tập dữ liệu công khai D_p , có thể truy cập bởi tất cả các thành viên liên kết. FedMD [?] là một công trình phổ biến sử dụng tập dữ liệu công khai có nhãn. Trong cách tiếp cận của họ, tất cả clients huấn luyện mô hình riêng trên tập dữ liệu công khai cho đến khi hội tụ, sau đó chuyển sang tập dữ liệu riêng trước quá trình liên kết. Với mỗi vòng liên kết, clients tính toán logits chưa qua hàm softmax cho mỗi mẫu của tập dữ liệu công khai. Máy chủ tổng hợp các logits của clients để tạo thành một consensus tổng kết biểu diễn của các mô hình tham gia lên từng mẫu công khai. Mỗi client huấn luyện mô hình cục bộ để phân phối dự đoán nhãn công khai của nó khớp với consensus này. Trong giai đoạn Digest của FedMD, consensus của máy chủ đóng vai trò là mô hình teacher, trong khi mỗi mô hình cục bộ đóng vai trò là mô hình student. Mỗi mô hình student học cách khớp đầu ra của nó trên các mẫu công khai với mô hình teacher là consensus thông qua một hạng tử trong hàm mất mát.

SSFL-IDS [?] tận dụng các nguyên lý của FD và học bán giám sát (semi-supervised learning). SSFL-IDS không yêu cầu tập dữ liệu công khai phải được gán nhãn. Trong cách tiếp cận của họ, mỗi client tối ưu hóa mô hình cục bộ bằng tập dữ liệu riêng và tính toán logits đã kích hoạt softmax trên các mẫu công khai. SSFL-IDS triển khai một mô hình phân loại nhị phân (discriminator) để loại bỏ các dự đoán trên các mẫu công khai mà mô hình chính không chắc chắn. SSFL-IDS dựa vào softmax score của mô hình chính trên dữ liệu cục bộ và dữ liệu công khai để chọn ra tập dữ liệu phân loại nhị phân, giúp mô hình discriminator phân biệt các dự đoán của mô hình chính lên các mẫu công khai thuộc nhãn lạ, qua đó mỗi client trong SSFL-IDS chỉ gửi các dự đoán mà mô hình có độ tự tin cao để server tổng hợp, giảm thiểu đặc tính lệch nhãn của môi trường Non-IID. Sau đó, phân phối softmax score của mỗi mẫu dữ liệu thông qua cơ chế majority voting để chọn

ra một nhãn giả (pseudo label) cho mẫu công khai tương ứng. Khi đó, bộ dữ liệu công khai, với nhãn giả, đã trở thành một bộ dữ liệu học giám sát đầy đủ, và mỗi client sẽ huấn luyện mô hình trên tập dữ liệu gán nhãn giả này như là một kiểu học liên kết.

2.2.3 Học liên kết phân tán (Decentralized Federated Learning)

Học liên kết phân tán (Decentralized Federated Learning – DFL) loại bỏ sự phụ thuộc vào máy chủ trung tâm vĩnh viễn bằng cách phân phối trách nhiệm điều phối giữa các clients tham gia [?]. Các iải pháp DFL hiện có được chia thành nhiều cấu trúc liên kết khác nhau, bao gồm kiến trúc vòng (ring), lưới (mesh), cụm (cluster) và hình sao (star). Các cấu trúc này khác nhau về độ phức tạp truyền thông, khả năng ổn định khi client dropout, tốc độ hội tụ của mô hình liên kết và thuật toán tổng hợp.

Trong số các cấu trúc này, DFL dạng hình sao duy trì hệ thống liên kết gần giống với FL tập trung nhất, nơi một điều phối viên tạm thời đứng ra thực hiện việc tổng hợp trong mỗi vòng liên kết. Không giống như FL tập trung, vai trò điều phối viên được chỉ định mới liên tục trong quá trình liên kết. BrainTorrent [?] là một công trình tiêu biểu trình bày một giải pháp FedAvg phân tán cho kiểu giao tiếp ngang hàng (peer-to-peer) theo cấu trúc hình sao.

Trong bối cảnh phát hiện xâm nhập, các nghiên cứu gần đây đã khám phá DFL-based IDS. 2DF-IDS [?] đề xuất một IDS dựa trên FL phân tán cho IIoT với cơ chế tổng hợp hoàn toàn phân tán. DOF-IDS [?] cho phép FL phân tán cho các nút IoT và IP với cách tiếp cận dựa trên đăng ký. Tuy nhiên, mặc dù các khung giải pháp này loại bỏ máy chủ trung tâm vĩnh viễn, hầu hết vẫn tiếp tục trao đổi tham số mô hình giữa các thành viên, để lại chi phí truyền thông và rủi ro đảo ngược mô hình như những thách thức đáng kể.

2.3 Tấn công độc hại (Poisoning Attacks) và Phòng thủ

Bản chất cộng tác của học liên kết khiến quá trình huấn luyện dễ bị tấn công bởi các thành viên độc hại làm hỏng quá trình tổng hợp. Thông qua việc thao túng dữ liệu huấn luyện cục bộ, bản cập nhật mô hình và không gian dự đoán, các cuộc tấn công đầu độc có thể làm suy giảm đáng kể hiệu suất mô hình toàn cục và đặt ra thách thức lớn cho việc triển khai thực tế các hệ thống phát hiện xâm nhập liên kết.

2.3.1 Tấn công đầu độc dữ liệu (Data Poisoning)

Tấn công đầu độc dữ liệu là một cuộc tấn công có thể được thực hiện trong tất cả các khung giải pháp liên kết. Nó thao túng tập dữ liệu huấn luyện cục bộ của các client Byzantine trước khi huấn luyện, thúc đẩy quá trình tối ưu hóa cục bộ tạo ra một mô hình bị đầu độc. Một ví dụ phổ biến trong bối cảnh phát hiện xâm nhập là đảo nhãn có chủ đích (targeted

label flipping), nơi các mẫu từ lớp tấn công thường xuyên xuất hiện được gán nhãn lại thành lưu lượng lành tính, buộc mô hình học các ranh giới quyết định sai. Các client bị đầu độc sau đó gửi các tham số mô hình bị đầu độc hoặc tạo ra các biểu diễn sai lệch ảnh hưởng xấu đến mô hình tổng hợp hoặc consensus.

2.3.2 Tấn công đầu độc mô hình (Model Poisoning)

Tấn công đầu độc mô hình sửa đổi các bản cập nhật mô hình cục bộ trước khi tổng hợp toàn cục, mà không cần bất kỳ dữ liệu huấn luyện nào. Kẻ tấn công có thể tạo ra các bản cập nhật tùy ý làm hỏng nghiêm trọng mô hình được tổng hợp một cách ngây thơ, khiến nó hoàn toàn không đáng tin cậy và làm đình trệ quá trình liên kết.

PoisonedFL [?] là một cuộc tấn công đầu độc mô hình gần đây có khả năng thích ứng với các phòng thủ hiện đại, bao gồm FLTrust [?] và FLAME [?]. Tất cả các client Byzantine trong cuộc tấn công này tạo ra một bản cập nhật bị đầu độc giống hệt nhau để giảm hiệu ứng “tự triệt tiêu” (self cancellation), đồng thời thích ứng bằng cách giảm cường độ tấn công nếu phát hiện sự hiện diện của cơ chế phòng thủ.

2.3.3 Tấn công đầu độc Logit (Logit Poisoning)

Trong các hệ thống chất lọc kiến thức liên kết, các client Byzantine trực tiếp thao túng các bản cập nhật biểu diễn ảnh hưởng xấu đến consensus tổng hợp. Tấn công tối đa hóa mất mát (Loss Maximization Attack – LMA) được giới thiệu bởi [?] tạo ra các logits đối nghịch nhằm tối đa hóa sự bất đồng trong quá trình tổng hợp, làm hỏng mô hình teacher consensus, và từ đó làm hỏng các mô hình student vốn là các mô hình lành tính.

Các cuộc tấn công đầu độc gần đây đã tiến hóa từ việc làm suy giảm FL bằng các giá trị ngoại lai cực đoan rõ ràng đến việc tạo ra các bản cập nhật độc hại ẩn danh nằm gần với hành vi Non-IID lành tính. Kết quả là, việc phân biệt các thành viên độc hại khỏi các client không đồng nhất tự nhiên ngày càng trở nên khó khăn.

2.3.4 Cơ chế phòng thủ (Anti-Poisoning)

Để giảm thiểu rủi ro từ các cuộc tấn công Byzantine, nhiều công trình nghiên cứu FL đã đề xuất các cơ chế khác nhau nhằm giảm hoặc loại bỏ hoàn toàn ảnh hưởng độc hại của các bản cập nhật trong quá trình tổng hợp.

Robust Aggregation Rule (RAR) đơn giản:

- **Coordinate-wise Median [?]:** Chọn giá trị trung vị cho mỗi tham số, loại bỏ các giá trị ngoại lai cực đoan.
- **TrimmedMean [?]:** Loại bỏ phần cao nhất và thấp nhất của các bản cập nhật client cho mỗi tham số.

- **Krum** [?]: Chọn bộ tham số gần nhất với tất cả các bộ tham số lân cận của nó.
- **Bulyan** [?]: Kết hợp Multi-Krum và TrimmedMean trong một quy trình tổng hợp thành hai bước.

Các phương pháp hiện đại:

- **FLAME** [?]: Máy chủ tính pair-wise cosine distance cho mỗi bản cập nhật client, phân cụm chúng bằng HDBSCAN [?], loại bỏ các cụm ngoại lai, cắt tỉa các mô hình (clipping) và áp dụng nhiễu (noising).
- **Cronus** [?]: Triển khai RobustFilter như một bộ tổng hợp logit chống chịu Byzantine, lọc các dự đoán ngoại lai trước khi gán nhãn giả (pseudo-labeling).
- **ExpGuard** [?]: Đo khoảng cách của mỗi bản cập nhật client so với kết quả tổng hợp của thuật toán tổng hợp RAR để tính điểm ngoại lai σ_k cho mỗi client, và tổng hợp mô hình sau cùng với điểm ngoại lai là trọng số tổng hợp.

2.3.5 Chất lọc kiến thức dựa trên bằng chứng (Evidential Knowledge Distillation)

Chất lọc kiến thức truyền thống truyền thụ tri thức thông qua các phân phối xác suất thu được bằng chuẩn hóa softmax. Mặc dù hiệu quả, softmax loại bỏ thông tin chứa trong độ lớn tuyệt đối của các logits, khiến các vector dự đoán với mức độ tin cậy khác nhau tạo ra các phân phối xác suất giống hệt nhau sau chuẩn hóa.

Chất lọc kiến thức dựa trên bằng chứng (Evidential Knowledge Distillation – EKD), được đề xuất bởi [?], truyền độ bất định của mô hình teacher cùng với kiến thức của nó đến các mô hình student. Trong EKD, các raw logits được kích hoạt bằng hàm mũ $e = \exp(z)$, kết hợp với trọng số tiên nghiệm λ để tạo ra vector tham số Dirichlet $|C|$ chiều $\alpha = e + \lambda$. Mô hình student chất lọc kiến thức từ mô hình teacher bằng cách tối ưu hóa:

$$\begin{aligned}
 L &= L_{1st} + \gamma L_{2nd} \\
 &= KL \left(\frac{\alpha_i^T}{\sum_{i \in C} \alpha_i^T} \parallel \frac{\alpha_i^S}{\sum_{i \in C} \alpha_i^S} \right) \\
 &\quad + \gamma \cdot KL(Dir(p^T | \alpha^T) || Dir(p^S | \alpha^S))
 \end{aligned} \tag{2.3}$$

2.3.6 Phát hiện ngoại phân phối dựa trên năng lượng (Energy-based OOD Detection)

Ước lượng độ tin cậy rất quan trọng trong việc xác định các dự đoán thiếu độ tự tin của mô hình. Các phương pháp truyền thống dựa trên xác suất softmax tối đa thường chịu hạn

chế là kết quả ước lượng quá tự tin ngay cả đối với các mẫu ngoài phân phối [?]. Phương pháp phát hiện OOD dựa trên năng lượng được đề xuất bởi [?] định lượng độ bất định của mô hình trên một mẫu dữ liệu x dưới dạng năng lượng:

$$E(x) = -T \log \sum_i e^{z_i/T} \quad (2.4)$$

Năng lượng thấp cho thấy dự đoán tin cậy do phân phối logit có độ lớn tập trung vào một kênh, trong khi giá trị năng lượng cao thường cho thấy một mẫu không chắc chắn hoặc ngoài phân phối do phân phối logit có độ lớn nhỏ và rải rác giữa các kênh.

CHƯƠNG 3

Phương pháp thực hiện


Các phương pháp FD hiện tại hỗ trợ hiệu quả các kiến trúc mô hình không đồng nhất, nhưng chúng hoặc vẫn dễ bị thao túng Byzantine, phụ thuộc vào điều phối tập trung, hoặc sử dụng một mô hình thứ hai để hỗ trợ tiết chế các dự đoán nhãn công khai kém tự tin. Để giải quyết các thách thức này, DFD-IDS là phương pháp đề xuất, bao gồm chất lọc kiến thức liên kết phân tán kết hợp cơ chế tiết chế dựa trên năng lượng, Chất lọc kiến thức dựa trên bằng chứng, tổng hợp logits chống tấn công Byzantine và lựa chọn phần tử điều phối phân tán. Trong DFD-IDS, các client tinh chỉnh mô hình qua học giám sát cục bộ và trao đổi các dự đoán được tiết chế bằng năng lượng trên một tập dữ liệu công khai. Một phần tử điều phối, được bầu chọn mới ở mỗi vòng liên kết từ các client, thu thập các dự đoán này cùng với một mặt nạ nhị phân biểu diễn giá trị tiết chế. Sau đó, logit của các client được lọc bằng thuật toán tổng hợp Blom Robust Filter được đề xuất. Cuối cùng, kiến thức tổng hợp được phân phối lại cho các client để thực hiện Chất lọc kiến thức dựa trên bằng chứng trước khi chuyển sang vòng học tiếp theo.

3.1 Tổng quan hệ thống

Vào đầu mỗi vòng học liên kết, mỗi client k thực hiện huấn luyện có giám sát cục bộ trên tập dữ liệu riêng của mình, tạo ra bộ logit $\bar{z}_k$ là dự đoán của mô hình trên tập dữ liệu cục bộ. Mô hình kết quả sau đó được sử dụng để đánh giá các mẫu từ tập dữ liệu công khai chia sẻ, tạo ra bộ logit $\bar{z}_{p,k}$ là dự đoán của mô hình trên tập dữ liệu công khai.

Từ bộ logit $\bar{z}_k$, mô hình sử dụng thuật toán ?? để sinh ra phân phối energy và chọn lọc dự đoán có độ tự tin cao trong $\bar{z}_{p,k}$. Quá trình này được mô tả chi tiết trong phần ??.

Phần tử điều phối thực hiện tổng hợp các bộ logit sử dụng Robust Logit Fusion như phần ?? đề xuất để xác định các dự đoán độc hại và tổng hợp bộ dự đoán đã được lọc các cập nhật độc hại. Phần tử điều phối tính điểm cho mỗi client từ kết quả lọc bằng một mặt nạ nhị phân o_k , tăng dần khi dự đoán của nó bị lọc. Chỉ những client có điểm thấp hơn ngưỡng đặt ra mới được giữ lại, và các dự đoán của chúng cũng phải vượt qua bước lọc trước đó để tham gia kết hợp logits cuối cùng. Các điểm số này cũng được sử dụng để xác



Hình 3.1: Workflow của khung giải pháp DFD-IDS.

định bộ điều phối trong vòng truyền thông tiếp theo.

Các logits tổng hợp được phân phối lại cho tất cả các client tham gia cho giai đoạn Chất lọc kiến thức dựa trên bằng chứng, trước khi tiến hành vòng truyền thông tiếp theo.

3.2 Cơ chế Energy-based Vote Abstention (EVA)

Các khung giải pháp chất lọc kiến thức liên kết hiện tại như FedMD [?] và FedDistill [?] thường xử lý tất cả các mẫu công khai như nhau trong quá trình trao đổi kiến thức. Trong môi trường Non-IID khắc nghiệt như dữ liệu mạng, tập dữ liệu công khai thường chứa các mẫu của các lớp thiểu số nằm ngoài phân phối của đa số clients. Do đó, các client này tạo ra các dự đoán thiếu sự chắc chắn trên những mẫu thuộc các lớp mà chúng chưa từng thấy, ảnh hưởng tiêu cực tới chất lượng của bộ logit được tổng hợp. Việc chất lọc kiến thức từ một bộ logit chất lượng suy giảm như vậy ảnh hưởng rất nặng lên mô hình học.

Để xử lý vấn đề này, phương pháp đề xuất cơ chế EVA. Mỗi client tính toán điểm năng lượng trên tập dữ liệu riêng của mình sử dụng Eq. ??, được coi là phân phối nội tại (in-distribution). Sau đó, phân vị (quantile) thứ q của điểm năng lượng cục bộ được chọn làm ngưỡng tin cậy riêng cho từng client:

$$\tau_k = Q_q(\{E(x)|x \in D_k\}) \quad (3.1)$$

trong đó Q_q là phân vị thứ q . Nghiên cứu phát hiện OOD dựa trên năng lượng [?] đánh giá hiệu suất sử dụng chỉ số FPR95, đo tỷ lệ False Positive khi True Positive của

các mẫu in-distribution được cố định ở 95%. Dựa vào đó, phương pháp đề xuất cũng cấu hình phân vị của EVA là thứ 95. Ngưỡng phân vị này phải cân đối giữa các giá trị energy cao đến từ các mẫu khó học trong phân phối dữ liệu cục bộ, cũng không được quá thấp để tránh tiết chế các dự đoán hoàn toàn có đủ độ tự tin của mô hình cục bộ.

Vì cơ chế EVA phụ thuộc hoàn toàn vào mô hình cục bộ và dữ liệu cục bộ, cơ chế này thích ứng tự nhiên với ngữ cảnh đa kiến trúc mô hình và bất đồng phân phối dữ liệu.

Tuy nhiên, trong các kịch bản Byzantine, các tác nhân Byzantine xem như bỏ qua cơ chế EVA này để tối đa hóa bề mặt tấn công. Nếu cơ chế EVA tiết chế hoàn toàn các dự đoán cục bộ từ phía client, các mẫu công khai thuộc nhãn hiếm sẽ bị các dự đoán của tác nhân Byzantine chiếm đa số, dẫn đến việc bộ lọc mất hiệu quả. Để giải quyết hạn chế này, mỗi client khởi tạo một mặt nạ nhị phân làm trọng số tổng hợp để đi kèm với toàn bộ dự đoán:

$$m_k(x) = \begin{cases} 1, & E_k(x) \leq \tau_k \\ 0, & \text{otherwise} \end{cases} \quad (3.2)$$

3.3 Robust Logit Fusion

3.3.1 Quy trình hoạt động

Sau khi các bộ logit dự đoán trên tập dữ liệu công khai được thu thập từ tất cả clients, phân tử điều phối tiến hành tổng hợp logit. Khi một phần clients là Byzantine gửi các dự đoán được tạo ra một cách đối nghịch, việc tổng hợp đơn giản (ví dụ: tổng hợp trung bình) sẽ trả về một bộ logit bị đầu độc. Thay vì đó, một quy trình tổng hợp hai lớp được đề xuất như trong Thuật toán ???. Các dự đoán của client trước tiên được lọc bằng Bộ lọc Blom Robust Filter cho mỗi mẫu công khai $x \in D_P$. Nếu bộ lọc từ chối dự đoán của client k cho mẫu x , một mặt nạ nhị phân theo từng mẫu $o_k(x)$ riêng cho mỗi client được đặt thành 1. Sau khi tất cả các mẫu công khai được xử lý, các client có điểm ngoại lai $\frac{1}{|D_P|} \sum_{x \in D_P} o_k(x)$ cao hơn tham số đặt trước ε sẽ bị loại bỏ và lượt đầu tiên hoàn thành. Các client còn lại bước vào lớp tổng hợp thứ hai, tổng hợp các dự đoán của tập client này thành một bộ logit sau cùng $\bar{z}(x)$, được tính như sau:

$$\bar{z}(x) = \frac{1}{|K|} \sum_{k \in K} m_k(x)(1 - o_k(x)) \cdot z_k(x) \quad (3.3)$$

trong đó $m_k(x)$ là mặt nạ bỏ phiếu trắng của client k cho mẫu công khai x được tính bằng EVA, $o_k(x)$ là mặt nạ ngoại lai nhị phân, và $z_k(x)$ là vector logit của k trên mẫu x .

Algorithm 1: Robust Logit Fusion**Input:** Dự đoán của clients trên các mẫu công khai $S(x), x \in D_p, S(x) = \{z_1, \dots, z_{|K|}(x)\}$, mặt nạ EVA $m_k(x), \forall x \in D_p, \forall k \in K$, ngưỡng ε **Output:** Consensus $\bar{z} = \{\bar{z}(x) | x \in D_p\}$

```

1 Khởi tạo  $o_k = \{o_k(x) | o \in [0, 1] x \in D_p\}, o_k(x) = 0, \forall k \in K$ 
2 foreach mẫu công khai  $x$  do
3   |   Loại client Byzantine bằng BlomRobustFilter (Thuật toán ??)
4   |    $K^a \leftarrow \text{BlomRobustFilter}(S(x), K)$ 
5   |   foreach client  $k \in K$  do
6   |   |   if  $k \notin K^a$  then
7   |   |   |    $o_k(x) = 1$ 
8   |   |   end
9   |   end
10 end
11 Cập nhật  $K = \{k \in K | \frac{1}{|D_p|} \sum_{x \in D_p} o_k(x) \leq \varepsilon\}$ 
12 foreach mẫu công khai  $x$  do
13   |   Tổng hợp consensus  $\bar{z}(x)$  qua Eq.??
14 end
15 return  $\bar{z}, o_k$ 

```

3.3.2 Blom Robust Filter

Một phương pháp FD có cùng cơ chế chống tấn công Byzantine là Cronus [?], bằng cách ứng dụng RobustFilter [?] để tổng hợp logits. RobustFilter của Cronus đã thành công trong việc chống các tấn công Byzantine nâng cao như ALIE [?], tuy nhiên hoạt động kém hơn so với tổng hợp trung bình trong ngữ cảnh lạnh tính. Trong thuật toán gốc, họ chọn một ngưỡng eigenvalue cố định là 9 và ma trận dự đoán được coi là lạnh tính nếu eigenvalue cao nhất của nó không vượt quá ngưỡng này. Việc chọn một ngưỡng cố định cho eigenvalue lớn nhất không lý tưởng, vì độ lớn của eigenvalue lớn nhất phụ thuộc vào cấu trúc covariance, kích thước client tham gia và số chiều của không gian logit.

Thay vì đặt ngưỡng trực tiếp trên eigenvalue cao nhất phụ thuộc vào số chiều, các dự đoán của client được biến đổi thành độ lệch chuẩn hóa bất biến với phép dịch chuyển và tỷ lệ. Với eigenvector v lớn nhất của ma trận dự đoán $S(x) = \{z_k(x) | k \in K\}$ trên một mẫu x duy nhất, và vector dự đoán trung bình $\bar{z}(x)$, mỗi vector logit của client được chiếu dọc theo v thành một giá trị vô hướng:

$$s_k(x) = v^\top (z_k(x) - \bar{z}(x))$$

và các giá trị này được chuẩn hóa thành độ lệch sử dụng median absolute deviation:

$$d_k(x) = \frac{|s_k(x) - \tilde{s}_k(x)|}{k \cdot \text{median}_{k \in K} |s_k(x) - \tilde{s}(x)|}$$

trong đó $k = 1/(\Phi(3/4)) \approx 1.4826$.

Sau khi chuẩn hóa, các độ lệch đã có thể so sánh được mà không phụ thuộc vào số client và số chiều của logit dự đoán. Do đó, việc đặt ngưỡng eigenvalue được thay thế bằng mô hình tham chiếu thống kê dựa trên thứ hạng. Các độ lệch của client được sắp xếp theo thứ tự tăng dần $d_{(1)} \leq \dots \leq d_{(|K|)}$. Độ lệch d_r ở mỗi thứ hạng r được so sánh với giá trị kỳ vọng b_r của nó dưới phân phối Half-normal cumulative distribution. Thống kê thứ tự Blom [?] được sử dụng để ước lượng giá trị kỳ vọng của từng thứ hạng trên phân phối này từ nghịch đảo xác suất:

$$b_r = \Phi^{-1} \left(\frac{1}{2} + \frac{1}{2} \cdot \frac{r - \alpha}{|K| - 2\alpha + 1} \right)$$

trong đó $\alpha = 0.375$. Do thống kê Blom trên phân phối Half-normal cumulative distribution rất nhạy trước các giá trị lệch mạnh, các client Non-IID lành tính có dự đoán khác so với đa số đôi khi có thể bị loại bỏ. Sự đánh đổi này là có chủ ý, vì các kỹ thuật tấn công Byzantine gần đây đã phát triển để khai thác tính không đồng nhất tự nhiên của các tập dữ liệu liên kết nhằm che giấu các cập nhật độc hại trong biến động Non-IID tự nhiên như Hidden-in-plain-sight (HIPS) [?] hoặc tự điều chỉnh mức tấn công để tiệm cận gần trung tâm của bộ tổng hợp ở các vòng liên kết trước [?].

Algorithm 2: Bộ lọc Blom Robust**Input:** Dự đoán của clients trên một mẫu x $S(x) = \{z_k(x) | k \in K\}$, $S(x) \in \mathbb{R}^{|K| \times |C|}$, tập client đang hoạt động $K^a \subseteq K$ **Output:** Tập client được chấp nhận K^a

```

1 while True do
2   Gọi  $S^a(x) = \{z_k(x) | k \in K^a\}$  là tập dự đoán của client đang hoạt động
3   Tính trung bình  $\bar{z}^a(x)$  và hiệp phương sai  $\Sigma_{S^a}$ 
4   Tìm eigenvector  $v$  hàng đầu của  $\Sigma_{S^a}$  với eigenvalue cao nhất  $\lambda_{max}(\Sigma_S)$ 
5    $v(x) = \arg \max_{\|u\|=1} u^\top \Sigma_S u$ 
6   Chiều dự đoán mỗi client  $k$  dọc theo  $v$  thành giá trị vô hướng
7    $s_k^a(x) = v^\top (z_k^a(x) - \bar{z}^a(x))$ 
8   Tìm trung vị của phép chiếu  $\tilde{s}^a(x) = \text{median}_{k \in K^a} s_k(x)$ 
9   Tìm ước lượng tỷ lệ dựa trên MAD
10   $\sigma^a(x) = 1.4826 \cdot \text{median}_{k \in K^a} |s_k^a(x) - \tilde{s}^a(x)|$ 
11  Tính độ lệch chuẩn hóa tuyệt đối cho mỗi client
12   $d_k^a(x) = \frac{|s_k^a(x) - \tilde{s}^a(x)|}{\sigma^a(x)}$ 
13  Tính giá trị kỳ vọng Blom cho thống kê thứ tự  $r$  của  $K^a$  biến chuẩn hóa
14   $b_r^a = \Phi^{-1} \left( \frac{1}{2} + \frac{1}{2} \cdot \frac{r-0.375}{|K^a|+0.25} \right)$ ,  $r = 1, \dots, |K^a|$ 
15  Sắp xếp các client đang hoạt động theo  $d_k^a(x)$  tăng dần; đặt
     $d_{(1)} \leq \dots \leq d_{(K^a)}$  là dãy đã sắp xếp với tham chiếu Blom  $b_1^a \leq \dots \leq b_{|K^a|}^a$ 
16  Định nghĩa khối hòa (tie block) của thứ hạng  $r$  là  $\mathcal{T}(r) = \{r' : d_{(r')} = d_{(r)}\}$ 
17  Loại bỏ client ở thứ hạng  $r$  nếu  $\exists r' \in \mathcal{T}(r)$  sao cho  $d_{(r')} > b_{r'}^a$ 
18   $K^a \leftarrow K^a \setminus \{k_{(r)} : \exists r' \in \mathcal{T}(r), d_{(r')} > b_{r'}^a\}$ 
19  if  $K^a$  unchanged or  $|K^a| \leq \lfloor \frac{|K|}{2} \rfloor$  then break;
20 end
21 return  $K^a$ 

```

3.4 Lựa chọn phần tử điều phối

Các phương pháp chất lọc kiến thức liên kết thông thường giả định một máy chủ trung tâm đáng tin cậy chịu trách nhiệm thu thập và tổng hợp dự đoán của clients. Giả định này tạo ra một điểm nghẽn trong hệ thống thực tế. Để loại bỏ sự phụ thuộc vào một bộ điều phối duy nhất, một hệ thống liên kết phân tán theo kiến trúc star được áp dụng, trong đó việc chỉ định làm phần tử điều phối liên tục thay đổi giữa các clients tham gia.

Trong vòng học liên kết đầu tiên, tất cả clients ngẫu nhiên chọn ra một phần tử điều phối. Client được chọn đóng vai trò là phần tử tổng hợp tạm thời, cùng với các ứng viên bổ sung đóng vai trò là bộ điều phối dự phòng trong trường hợp client được chọn dropout.

Trong các vòng tiếp theo, việc lựa chọn bộ điều phối được quyết định bởi kết quả của bộ lọc Blom Robust Filter (??). Client có tần suất bị lọc thấp nhất được bầu làm máy chủ

tổng hợp cho vòng tiếp theo, trong khi các client có tần suất bị lọc gần với điểm thấp nhất được bầu làm dự phòng.

3.5 Evidential Knowledge Distillation trong DFD-IDS

Sau khi quá trình kết hợp logits hoàn tất trong DFD-IDS, mỗi client, với consensus $\bar{z} = \{\bar{z}(x)|x \in D_p\}$ đã nhận và tập logits dự đoán riêng $\bar{z}_{p,k} = \{z_k(x), x \in D_p\}$, chất lọc kiến thức từ consensus bằng phương pháp chất lọc kiến thức EKD. Chúng tính toán vector tham số Dirichlet cho mỗi vector consensus và vector logits tương ứng:

$$\alpha^T = \exp(\bar{z}(x)) + \lambda_{\text{weight}}$$

$$\alpha^S = \exp(z_k(x)) + \lambda_{\text{weight}}$$

trong đó $\exp()$ là hàm mũ, λ_{weight} là trọng số tiên nghiệm và $\lambda_{\text{weight}} = 1$ được chọn. Sau đó, mỗi client chất lọc kiến thức bằng cách tối ưu hóa hàm mất mát (??) cho tất cả các mẫu công khai x với consensus và vector dự đoán tương ứng.

Algorithm 3: DFD-IDS

Input: Tập client phân tán K , tập dữ liệu riêng $D_k, \forall k \in K$, tập dữ liệu công khai không nhãn D_p , mô hình client f_k với tham số w_k , ngưỡng ε , số vòng liên kết $t \in T$

```

1 Khởi tạo máy chủ tổng hợp tạm thời và dự phòng,  $k_s, k_b \leftarrow RNG(K, \text{seed})$ 
2 foreach vòng  $t \in T$  do
3   foreach client  $k \in K$  do
4      $w_k \leftarrow$  Học có giám sát( $w_k, D_k$ )
5     Tính ngưỡng điểm năng lượng  $\tau_k$  (Eq. ?? và ??)
6     Tạo logits  $z_k(x)$  cho mẫu công khai  $x \in D_p$ 
7     Tạo mất nạ EVA  $m_k(x)$  với Eq. ??
8   end
9   Với  $k_s$  là máy chủ tổng hợp, thực hiện Kết hợp Logits chống chịu đầu độc
    với dự đoán client  $z_k(x)$  và mất nạ EVA  $m_k(x)$  sử dụng Thuật toán ?? để
    nhận consensus  $\bar{z}$  và điểm ngoại lai client  $o_k$ 
10  Bầu chọn máy chủ tổng hợp mới và  $|k_b|$  dự phòng
     $(k_s, \{k_b\}) \leftarrow TopMins(o_k, |k_b| + 1)$ 
11  foreach client  $k \in K$  do
12    Thực hiện Chất lọc kiến thức dựa trên bằng chứng với consensus  $\bar{z}$ 
13  end
14 end
```

CHƯƠNG 4

Thực nghiệm và đánh giá

4.1 Môi trường thực nghiệm

Tất cả các đánh giá được thực hiện bằng Python 3, sử dụng framework Torch phiên bản 2.12.0, CUDA 13.2 cùng với các thư viện khác như Scikit-learn, NumPy, Pandas, pickle... Các thực nghiệm được tiến hành trên một máy Windows Subsystems for Linux (WSL2) với cấu hình CPU Intel Core[®] i9-13900K (16 nhân 2.9 GHz), RAM 22 GB và ổ cứng 1TB SSD NVMe Gen 4.

4.1.1 Tiền xử lý dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu này là CICIoT2023 [?], một tập dữ liệu phát hiện xâm nhập quy mô lớn được thu thập trên hạ tầng thiết bị IoT thực tế. Trước khi đưa vào huấn luyện, dữ liệu thô được làm sạch bằng cách loại bỏ các bản ghi mang giá trị rỗng, giá trị vô cực hoặc bản ghi trùng lặp, đồng thời các đặc trưng số được chuẩn hoá về cùng một thang đo để tránh việc một vài đặc trưng có biên độ lớn lấn át quá trình học. Sau bước chuẩn hoá, mỗi luồng mạng được biểu diễn bằng một vector đặc trưng 20 chiều, trong đó 20 cột đầu đóng vai trò là đầu vào của mô hình còn cột cuối cùng lưu nhận lớp tương ứng.

Tập đặc trưng 20 chiều bao quát nhiều khía cạnh của một luồng mạng, từ đặc tính thời gian, kích thước và thống kê gói, đến các cờ giao thức TCP cùng tỉ lệ phân bố giao thức. Bảng ?? liệt kê đầy đủ 20 đặc trưng, được nhóm lại theo bản chất nhằm thuận tiện cho phần thảo luận sau này. Việc giới hạn ở 20 đặc trưng giúp giảm chi phí huấn luyện trong mô phỏng nhiều client, đồng thời vẫn bảo toàn các tín hiệu quan trọng để phân biệt lưu lượng bình thường với các nhóm tấn công.

Bảng 4.1: Tập 20 đặc trưng đầu vào của CICIOT2023.

Nhóm đặc trưng	Tên đặc trưng
Thời gian luồng	flow_duration, IAT
Kích thước gói	Tot size, Tot sum, AVG, Min, Max, Magnitue, Header_Length
Cờ TCP (xuất hiện)	syn_flag_number, ack_flag_number, psh_flag_number, rst_flag_number, fin_flag_number
Số đếm cờ TCP	syn_count, ack_count, rst_count
Tỉ lệ giao thức	TCP, UDP, ICMP

Tập dữ liệu sau tiền xử lý chứa 46,905,384 bản ghi trải trên 34 lớp, gồm một lớp lưu lượng bình thường (BenignTraffic) và 33 lớp tấn công thuộc nhiều nhóm khác nhau. Một đặc điểm nổi bật của CICIOT2023 là phân phối lớp mất cân bằng nghiêm trọng: lớp đa số DDoS-ICMP_Flood chiếm 15.42% tổng số bản ghi, trong khi lớp Uploading_Attack chỉ có 1,257 mẫu. Sự chênh lệch hàng nghìn lần giữa lớp giàu nhất và lớp nghèo nhất khiến cho việc phát hiện các lớp thiểu số trở thành thách thức trọng tâm, đặc biệt khi dữ liệu lại tiếp tục bị phân mảnh và lệch nhãn trong môi trường học liên kết.


4.1.2 Phân bổ dữ liệu phi IID

Toàn bộ tập dữ liệu sau tiền xử lý được phân hoạch cho client theo ngữ cảnh Non-IID, đồng thời một tập kiểm thử toàn cục được giữ cố định và dùng chung cho mọi thuật toán nhằm bảo đảm việc so sánh diễn ra trên cùng một thước đo. Tập kiểm thử này được tách theo phân tầng giữ nguyên tỉ lệ lớp, nên phân phối nhãn trên tập kiểm thử trùng khớp với phân phối trên toàn tập, qua đó các lớp thiểu số vẫn hiện diện đầy đủ trong quá trình đánh giá.

Sau khi dữ liệu được tách theo lớp, mỗi lớp được phân bổ cho client theo ngữ cảnh Non-IID lệch nhãn (label skew), trong đó số mẫu của một lớp trên các client được lấy từ phân phối Dirichlet:

$$\pi_c \sim \text{Dir}(\alpha \mathbf{1}_{|K|}), \quad n_{k,c} = \lfloor \pi_{k,c} N_c \rfloor,$$

trong đó N_c là số mẫu của lớp c , $|K|$ là số client và $n_{k,c}$ là số mẫu lớp c được cấp cho client k . Vì phép lấy mẫu được lặp lại độc lập cho từng lớp, một client có thể giàu dữ liệu ở vài lớp nhưng thiếu nghiêm trọng ở các lớp khác, phản ánh tình huống IDS trong đó mỗi tổ chức chỉ quan sát được một phần của không gian tấn công. Tham số α điều khiển mức độ lệch nhãn; trong các thí nghiệm chính, $\alpha = 0.1$ được sử dụng để tái tạo ngữ cảnh lệch nhãn nghiêm trọng.



Hình 4.1: Phân phối dữ liệu theo lớp cho 100 client.

Sau khi phân hoạch, một tỉ lệ ngẫu nhiên trong khoảng [5%, 20%] số mẫu của từng client được tách ra làm phần dữ liệu công khai, phần còn lại giữ làm dữ liệu riêng. Vì tỉ lệ cắt được lấy độc lập cho mỗi client, tổng phần công khai trên toàn hệ thống là 7,935,448 mẫu (16.92%), còn 38,969,936 mẫu (83.08%) được giữ làm dữ liệu riêng cho huấn luyện giám sát cục bộ.

4.2 Các chỉ số đánh giá

Hiệu quả của giải pháp đề xuất được đánh giá bằng các chỉ số tiêu chuẩn sau:

Accuracy (Acc) Chỉ số này là tỷ lệ các mẫu được dự đoán đúng trên tổng số mẫu trong tập kiểm tra:

$$Acc = \frac{TP + TN}{\text{Tổng số mẫu}} \quad (4.1)$$

Precision Tỷ lệ các mẫu dương tính được dự đoán đúng trên tất cả các mẫu được dự đoán là dương tính:

$$Precision = \frac{TP}{TP + FP} \quad (4.2)$$

Recall Tỷ lệ các mẫu dương tính được dự đoán đúng trên tất cả các mẫu dương tính thực tế:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4.3)$$

F1-Score Trung bình điều hòa của Precision và Recall:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.4)$$

trong đó TP là số mẫu dương tính được dự đoán đúng, TN là số mẫu âm tính được dự đoán đúng, FP là số mẫu âm tính bị dự đoán sai thành dương tính, và FN là số mẫu dương tính bị dự đoán sai thành âm tính.

Trong các bảng kết quả thực nghiệm, Precision, Recall và F1-Score được tính theo trung bình macro (macro-averaging), tức là tính toán các chỉ số trên từng lớp riêng biệt rồi lấy trung bình cộng. Phương pháp này phù hợp với dữ liệu mạng vốn mất cân bằng lớp nghiêm trọng, tránh trường hợp các lớp đa số lấn át các lớp thiểu số.

4.3 Kịch bản thực nghiệm

Để đánh giá toàn diện hiệu quả của DFD-IDS, các kịch bản thực nghiệm sau được xây dựng:

4.3.1 Kịch bản không tấn công

Trong kịch bản này, tất cả clients đều trung thực, không có tác nhân Byzantine. Mục tiêu là đánh giá hiệu suất cơ bản của DFD-IDS trong môi trường lý tưởng và so sánh với các phương pháp FL truyền thống.

4.3.2 Kịch bản tấn công data poisoning

Ở kịch bản data poisoning, một tỉ lệ client sẽ đóng vai Byzantine, mỗi client Byzantine sử dụng kỹ thuật Targetted Label Flipping [?] để lật nhãn của lớp có nhiều dữ liệu trong tập dữ liệu cục bộ của nó nhất thành nhãn Benign.

4.3.3 Kịch bản tấn công đầu độc trọng số mô hình

Ở kịch bản đầu độc trọng số mô hình, một tỉ lệ client sử dụng kỹ thuật PoisonedFL [?] để thống nhất cùng gửi một cập nhật đầu độc có khả năng thích nghi qua từng vòng liên kết.

PoisonedFL là một phương pháp tấn công Byzantine không toàn tri (non-omniscient) nhắm vào các phòng thủ FL. Điểm mới chính của PoisonedFL là hướng tấn công nhất quán và cường độ được tính toán qua nhiều vòng. Các client Byzantine thỏa thuận một

ma trận đầu chung $s \in \{-1, +1\}^d$ và tạo ra một bản cập nhật mô hình đầu độc $g_b^t = s \odot k^t$, trong đó $k^t = \lambda^t \cdot v^t$ với λ^t kiểm soát cường độ và v^t kiểm soát hướng của vector tấn công. Vector v^t được tính dựa trên chênh lệch giữa bản cập nhật tổng hợp và bản cập nhật đầu độc đã chuẩn hóa từ vòng trước, nhằm căn chỉnh cường độ tấn công với cường độ của các bản cập nhật lành tính. Hệ số λ^t được điều chỉnh thích ứng dựa trên giả thuyết H_0 (tấn công không hiệu quả) hoặc H_1 (tấn công thành công), sử dụng phép kiểm định nhị thức trên số chiều của mô hình toàn cục. Nếu H_0 được chấp nhận, cường độ tấn công bị giảm theo hệ số $\beta < 1$ để tránh bị phát hiện. PoisonedFL tận dụng tính không đồng nhất tự nhiên của dữ liệu Non-IID để che giấu các cập nhật độc hại, khiến nó trở thành một trong những cuộc tấn công nguy hiểm nhất trong bối cảnh FL.

PoisonedFL là kỹ thuật tấn công Byzantine dành cho các thuật toán FL có tồn tại một mô hình toàn cục. Vì các thuật toán FD không sử dụng mô hình toàn cục, PoisonedFL đã được thiết kế lại để thích nghi với FD. Cụ thể, để ước tính mô hình toàn cục cho PoisonedFL, mỗi client Byzantine thực hiện học chất lọc trên bộ consensus hoặc tập biểu diễn trung gian.

- Ở các thuật toán sử dụng dữ liệu công khai, các client PoisonedFL chỉ cần chất lọc hoặc học giám sát trên tập dữ liệu công khai này.
- Trong các thuật toán không sử dụng dữ liệu công khai như FedProto, các client PoisonedFL kết hợp dữ liệu của chính nó và chất lọc trên biểu diễn toàn cục (global prototypes) để ước tính mô hình toàn cục, sau đó chúng trung bình cộng các bản mô hình đã được ước tính thành một mô hình toàn cục sau cùng để tính toán cập nhật bị đầu độc.

Do điều kiện không toàn tri, các client PoisonedFL chỉ có thể bắt đầu tấn công khi đã có ít nhất hai bộ biểu diễn trung gian, hai bộ mô hình toàn cục, hoặc hai bộ consensus.

Mỗi kịch bản tấn công được đánh giá với các tỷ lệ Byzantine khác nhau (20%, 50%) để quan sát biểu hiện của các phương pháp so sánh ở điều kiện tỉ lệ Byzantine bình thường và tỉ lệ Byzantine chiếm gần đa số.

4.3.4 Kịch bản đa kiến trúc mô hình

Trong kịch bản này, tập client được chia ra 4 nhóm mô hình, trong đó nhóm 1 sử dụng mô hình GRU, nhóm 2 sử dụng mô hình DCNN-BiLSTM, nhóm 3 sử dụng mô hình MLP và nhóm cuối cùng sử dụng mô hình CNN.

4.4 Thiết lập mô hình

Các mô hình chính trong thí nghiệm được hiện thực bằng PyTorch. Đầu vào của mỗi mô hình là vector đặc trưng $x \in \mathbb{R}^{20}$, còn đầu ra là vector logits có kích thước bằng số lớp

hiện tại. Trong chế độ dự đoán, logits được đưa qua hàm softmax để tạo phân phối xác suất; trong huấn luyện, loss được tính trực tiếp trên logits để giữ ổn định số học.

Tất cả các mô hình phân loại dùng Adam làm bộ tối ưu. Learning rate mặc định được co giãn theo batch size:

$$\eta = 10^{-3} \sqrt{\frac{B}{1024}},$$

trong đó B là batch size. Batch size mặc định là 8192. Learning rate dùng warm-up tuyến tính:

$$\eta_e = \eta \frac{e + 1}{5}.$$

Hàm mất mát cho học giám sát là cross-entropy với label smoothing 0.05. Gradient được chuẩn hoá bằng clipping theo chuẩn ℓ_2 với ngưỡng 0.5. Một số lớp tuyến tính được áp dụng weight decay 10^{-4} để giảm overfitting, trong khi các tham số còn lại không dùng weight decay. Các mô hình dùng LayerNorm thay cho BatchNorm vì thí nghiệm có batch lớn, dữ liệu Non-IID và phân phối giữa client khác nhau; LayerNorm giúp chuẩn hoá biểu diễn theo từng mẫu và ít phụ thuộc thống kê batch hơn.

4.4.1 Mô hình GRU

GRU [?] xử lý vector 20 chiều như chuỗi một chiều có độ dài 20, mỗi bước thời gian chứa một giá trị đặc trưng. Cách biểu diễn này cho phép mô hình học quan hệ tuần tự tương đối giữa các đặc trưng sau tiên xử lý, đồng thời vẫn giữ chi phí thấp hơn BiLSTM. Bảng ?? trình bày kiến trúc GRU.

Bảng 4.2: Kiến trúc GRU dùng trong thí nghiệm.

	l c X	
	Tầng	Kích thước Thiết lập
Reshape	20 $\rightarrow$ 20 $\times$ 1	Mỗi đặc trưng là một bước chuỗi
GRU 1	1 $\rightarrow$ 128	Trả về toàn bộ chuỗi, LayerNorm, Dropout 0.15
GRU 2	128 $\rightarrow$ 128	Trả về toàn bộ chuỗi, LayerNorm, Dropout 0.15
GRU 3	128 $\rightarrow$ 128	Lấy trạng thái cuối, LayerNorm, Dropout 0.15
Dense head	128 $\rightarrow$ 64	ReLU, LayerNorm, Dropout 0.20
Classifier	64 $\rightarrow$ C	Logits theo số lớp C

Ba tầng GRU liên tiếp cho phép mô hình tích lũy tương tác phi tuyến giữa các đặc trưng. Hai tầng đầu giữ toàn bộ chuỗi để tầng sau tiếp tục xử lý thông tin theo vị trí đặc trưng, còn tầng cuối chỉ lấy trạng thái cuối làm biểu diễn toàn cục. Dense head dùng ReLU vì đây là tầng nén cuối trước logits, cần ánh xạ rõ ràng và gọn hơn thay vì giữ dạng kích hoạt trơn như MLP.

4.4.2 Mô hình DCNN–BiLSTM

DCNN–BiLSTM [?] là mô hình sâu hơn, kết hợp trích xuất mẫu cục bộ bằng tích chập một chiều và mô hình hoá phụ thuộc hai chiều bằng BiLSTM. Bảng ?? mô tả kiến trúc của mô hình này.

Bảng 4.3: Kiến trúc CNN–BiLSTM dùng trong thí nghiệm.

l c X		
Tầng	Kích thước	Thiết lập
Reshape	$20 \rightarrow 1 \times 20$	Một kênh đầu vào
Conv1D	$1 \rightarrow 64$	Kernel size 20, padding same, ReLU, LayerNorm
BiLSTM 1	$64 \rightarrow 2 \times 64$	Trả về toàn bộ chuỗi, LayerNorm
BiLSTM 2	$128 \rightarrow 2 \times 128$	Lấy trạng thái cuối hai chiều, Dropout 0.10
DNN 1	$256 \rightarrow 64$	ReLU, Dropout 0.10
DNN 2	$64 \rightarrow 32$	ReLU, Dropout 0.10
DNN 3	$32 \rightarrow 16$	ReLU, Dropout 0.10
LayerNorm	16	Chuẩn hoá biểu diễn cuối
Classifier	$16 \rightarrow C$	Logits theo số lớp C

Tầng CNN đầu tiên đóng vai trò bộ trích xuất mẫu cục bộ trên toàn bộ vector đặc trưng. Do kernel size bằng số chiều đầu vào, mỗi filter học một phép chiếu có cấu trúc qua toàn bộ đặc trưng, sau đó BiLSTM khai thác biểu diễn theo hai hướng. Việc dùng hai tầng BiLSTM giúp mô hình học cả quan hệ thấp và quan hệ trừu tượng hơn, còn khối DNN cuối giảm chiều biểu diễn trước khi phân loại.

4.4.3 Mô hình Multi Layer Perceptron

MLP được dùng làm mô hình đơn giản cho dữ liệu vector 20 chiều. Kiến trúc này ưu tiên độ ổn định và tốc độ, phù hợp với các thí nghiệm nhiều client. Bảng ?? mô tả các tầng chính.

Bảng 4.4: Kiến trúc MLP dùng trong thí nghiệm.

Tầng	Kích thước	Thiết lập
Input	20	Vector đặc trưng luồng mạng
LayerNorm	20	Chuẩn hoá đầu vào
Linear 1	$20 \rightarrow 128$	SiLU, LayerNorm, Dropout 0.15
Linear 2	$128 \rightarrow 128$	SiLU, LayerNorm, Dropout 0.20, residual
Linear 3	$128 \rightarrow 64$	SiLU, LayerNorm, Dropout 0.15
Classifier	$64 \rightarrow C$	Logits theo số lớp C

Hàm kích hoạt SiLU được chọn thay cho ReLU ở các tầng ẩn vì SiLU có dạng trơn, giảm hiện tượng gradient bằng không ở vùng âm và thường ổn định hơn trên dữ liệu bảng sau chuẩn hoá. Kết nối residual ở tầng $128 \rightarrow 128$ giúp mô hình học hiệu chỉnh trên biểu diễn trung gian thay vì phải tái tạo toàn bộ ánh xạ.

4.4.4 Mô hình CNN

CNN một chiều là một mô hình có kiến trúc nông, đóng vai trò straggler trong kịch bản mô hình hỗn hợp, nơi một phần client chạy kiến trúc nông và nhẹ hơn so với GRU hay DCNN-BiLSTM. Vector đặc trưng 20 chiều được xem như một chuỗi một kênh, sau đó được xử lý qua ba khối tích chập một chiều liên tiếp nhằm trích xuất mẫu cục bộ ở nhiều mức độ trừu tượng. Bảng ?? mô tả các tầng chính của kiến trúc này.

Bảng 4.5: Kiến trúc CNN dùng làm mô hình straggler.

Tầng	Kích thước	Thiết lập
Reshape	$20 \rightarrow 1 \times 20$	Một kênh đầu vào
Conv1D 1	$1 \rightarrow 32$	Kernel 3, padding 1, BatchNorm, ReLU, Dropout 0.15
MaxPool 1	/2	Giảm chiều theo hệ số 2
Conv1D 2	$32 \rightarrow 64$	Kernel 3, padding 1, BatchNorm, ReLU, Dropout 0.15
MaxPool 2	/2	Giảm chiều theo hệ số 2
Conv1D 3	$64 \rightarrow 64$	Kernel 3, padding 1, BatchNorm, ReLU, Dropout 0.15
GAP	64	Adaptive average pooling
FC	$64 \rightarrow 64$	SiLU, LayerNorm, Dropout 0.20
Classifier	$64 \rightarrow C$	Logits theo số lớp C

Khác với các kiến trúc còn lại vốn dựa trên LayerNorm, các khối tích chập của CNN được chuẩn hoá bằng BatchNorm, do biểu diễn tích chập ổn định hơn khi được chuẩn hoá theo từng kênh trên toàn batch. Sau ba khối tích chập, một tầng adaptive average pooling nén chuỗi đặc trưng về một vector cố định, nhờ đó phần đầu phân loại không phụ thuộc vào độ dài chuỗi trung gian.

4.5 Kết quả thực nghiệm

4.5.1 Kết quả thực nghiệm trong môi trường không tấn công

Trong môi trường lành tính (không có client Byzantine), DFD-IDS đạt hiệu suất cạnh tranh so với các phương pháp Học liên kết tập trung, đồng thời mang lại các lợi ích bổ sung như điều phối phân tán và chi phí truyền thông giảm. Cơ chế Energy-based Vote Abstention

lọc hiệu quả các dự đoán không chắc chắn, tạo ra một consensus sạch hơn cho quá trình chất lọc kiến thức.

Bảng 4.6: Kịch bản không tấn công

lccccX				
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)
Federated Distillation (FD)				
Đề xuất	0.9415	0.5401	0.5121	0.5056
SSFL-IDS	0.9605	0.5831	0.5849	0.5651
FedKD-IDS	0.9484	0.5015	0.4894	0.4795
FedProto	0.3968	0.2072	0.108	0.1223
Federated Learning (FL)				
FedAvg	0.9656	0.5141	0.5851	0.5105
FLAME	0.9454	0.5368	0.5520	0.5112

Bảng 4.7: Kịch bản không tấn công – đa kiến trúc mô hình

lccccX				
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)
Đề xuất	0.9346	0.471	0.4745	0.4553
SSFL-IDS	0.8943	0.4922	0.4972	0.4735
FedKD-IDS	0.7785	0.467	0.43	0.4267
FedProto	0.5400	0.321	0.2171	0.2273

4.5.2 Kết quả thực nghiệm trong môi trường Byzantine

Tấn công Targeted Flip

Bảng 4.8: Kết quả tấn công Targeted Flip (tỉ lệ Byzantine 0.2)

lccccX				
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)
Federated Distillation (FD)				
Đề xuất	0.9582	0.5500	0.5131	0.5188
SSFL-IDS	0.9550	0.5069	0.4981	0.4904
FedKD-IDS	0.9500	0.5138	0.5079	0.4928
FedProto	0.5666	0.3355	0.2242	0.2399
Federated Learning (FL)				
FedAvg	0.9674	0.5272	0.6153	0.5182
FLAME	0.9088	0.5386	0.5738	0.5211

Bảng 4.9: Đa kiến trúc mô hình dưới tấn công Targeted Flip (tỉ lệ Byzantine 0.2)

lccccX					
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)	
Đề xuất	0.9306	0.4882	0.487	0.4713	
SSFL-IDS	0.8954	0.4897	0.4976	0.4763	
FedKD-IDS	0.7758	0.4487	0.4061	0.3992	
FedProto	0.5487	0.3263	0.2253	0.2335	

Bảng 4.10: Kết quả tấn công Targeted Flip (tỉ lệ Byzantine 0.5)

lccccX					
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)	
Federated Distillation (FD)					
Đề xuất	0.8431	0.476	0.4684	0.4427	
SSFL-IDS	0.9575	0.5397	0.5347	0.5178	
FedKD-IDS	0.7346	0.3974	0.3184	0.3383	
FedProto	0.5565	0.3266	0.2165	0.2317	
Federated Learning (FL)					
FedAvg	0.9726	0.5449	0.6119	0.5357	
FLAME	0.6889	0.4746	0.4846	0.4246	

Bảng 4.11: Đa kiến trúc mô hình dưới tấn công Targeted Flip (tỉ lệ Byzantine 0.5)

lccccX					
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)	
Đề xuất	0.9281	0.4965	0.4781	0.4675	
SSFL-IDS	0.951	0.5057	0.485	0.4878	
FedKD-IDS	0.822	0.4598	0.427	0.4259	
FedProto	0.5263	0.3137	0.2055	0.2178	

Tấn công PoisonedFL

Bảng 4.12: Kết quả tấn công PoisonedFL (tỉ lệ Byzantine 0.2)

lcxxxX				
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)
Federated Distillation (FD)				
Đề xuất	0.9554	0.5250	0.5024	0.5063
SSFL-IDS	0.0061	0.0294	0.0002	0.0004
FedKD-IDS	0.7173	0.3043	0.2583	0.2570
FedProto	0.1508	0.0573	0.0168	0.0213
Federated Learning (FL)				
FedAvg	0.0235	0.0294	0.0007	0.0014
FLAME	0.7292	0.4237	0.4576	0.3808

Bảng 4.13: Đa kiến trúc mô hình dưới tấn công PoisonedFL (tỉ lệ Byzantine 0.2)

lcxxxX				
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)
Đề xuất	0.918	0.4739	0.4636	0.4505
SSFL-IDS	0.0887	0.0341	0.0323	0.0323
FedKD-IDS	0.784	0.4397	0.4607	0.4065
FedProto	0.0235	0.0294	0.0007	0.0014

Bảng 4.14: Kết quả tấn công PoisonedFL (tỉ lệ Byzantine 0.5)

lcxxxX				
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)
Federated Distillation (FD)				
Đề xuất	0.6951	0.3595	0.2833	0.2798
SSFL-IDS	0.0235	0.0294	0.0007	0.0014
FedKD-IDS	0.9572	0.5396	0.5276	0.5188
FedProto	0.1087	0.0411	0.0101	0.0125
Federated Learning (FL)				
FedAvg	0.0235	0.0294	0.0007	0.0014
FLAME	0.0617	0.0239	0.0098	0.0092

Bảng 4.15: Đa kiến trúc mô hình dưới tấn công PoisonedFL (tỉ lệ Byzantine 0.5)

lccccX					
Phương pháp	Acc	Recall (macro)	Precision (macro)	F1 (macro)	
FedKD-IDS	0.8483	0.3915	0.4346	0.3732	
Đề xuất	0.4561	0.2758	0.1987	0.1968	
SSFL-IDS	0.0235	0.0294	0.0007	0.0014	
FedProto	0.0235	0.0294	0.0007	0.0014	

4.5.3 Phân tích kết quả

Trong kịch bản không tấn công, Đề xuất đạt Accuracy 0.9415 và F1 macro 0.5056, thấp hơn SSFL-IDS và FedAvg ở một vài chỉ số tổng quát nhưng vẫn duy trì vùng hiệu năng cạnh tranh. Điểm đáng chú ý là loss của Đề xuất thấp thứ hai trong toàn bảng, cho thấy quá trình chất lọc tạo ra dự đoán tương đối ổn định ngay cả khi hệ thống không có client độc hại. Điều này phù hợp với mục tiêu thiết kế: phương pháp không chỉ tối ưu một mô hình toàn cục duy nhất, mà tạo consensus từ các dự đoán đủ tin cậy để làm tín hiệu huấn luyện chung.

Ở tấn công Targeted Flip với tỉ lệ Byzantine 0.2, Đề xuất đứng trong nhóm dẫn đầu trên Accuracy, Recall macro, F1 macro và đạt loss thấp nhất. Kết quả này cho thấy cơ chế lọc theo năng lượng và hợp nhất logits không chỉ loại bỏ các dự đoán bất thường mà còn giữ lại đủ tín hiệu của các client lành tính để bảo toàn hiệu quả phân loại. Khi tỉ lệ Byzantine tăng lên 0.5, hiệu năng của Đề xuất giảm rõ rệt, nhưng vẫn cao hơn FedKD-IDS, FedProto và FLAME ở Accuracy. Sự suy giảm này phản ánh giới hạn tự nhiên của đồng thuận khi số client độc hại tiến gần đa số; tuy nhiên phương pháp vẫn không sụp đổ hoàn toàn như một số cơ chế phòng thủ dựa vào khoảng cách hoặc prototype đơn giản.

Trong kịch bản PoisonedFL, sự khác biệt giữa các phương pháp trở nên rõ hơn. Với tỉ lệ Byzantine 0.2, Đề xuất đạt kết quả tốt nhất trên toàn bộ các chỉ số chính và giữ loss thấp nhất, trong khi FedAvg và SSFL-IDS gần như mất khả năng phân loại. Điều này cho thấy việc không trực tiếp tổng hợp trọng số mô hình giúp Đề xuất tránh được hướng tấn công vốn được thiết kế để thao túng cập nhật tham số. Ở tỉ lệ Byzantine 0.5, FedKD-IDS đạt kết quả cao nhất, còn Đề xuất giảm xuống mức trung gian. Dù vậy, Đề xuất vẫn vượt xa FedAvg, SSFL-IDS, FedProto và FLAME, cho thấy hệ thống còn giữ được một phần khả năng kháng nhiễu ngay cả khi tín hiệu độc hại chiếm tỉ trọng rất lớn.

Trong cấu hình đa kiến trúc mô hình (các bảng đánh dấu “đa kiến trúc” trong từng kịch bản), Đề xuất cho thấy ưu điểm hệ thống quan trọng. Trong môi trường không tấn công và Targeted Flip, phương pháp duy trì Accuracy trên 0.92 và thường nằm trong nhóm hai phương pháp tốt nhất, dù các client sử dụng GRU, DCNN-BiLSTM, MLP và CNN đồng thời. Ở PoisonedFL với tỉ lệ Byzantine 0.2, Đề xuất tiếp tục dẫn đầu tất cả các chỉ số chính, trong khi SSFL-IDS và FedProto gần như bị vô hiệu hoá. Khi tỉ lệ Byzantine tăng lên 0.5, Đề xuất không còn đạt kết quả tốt nhất nhưng vẫn vượt SSFL-IDS và FedProto,

cho thấy trao đổi logits trên dữ liệu công khai là một hướng phù hợp cho môi trường vừa bất đồng nhất kiến trúc vừa có nguy cơ Byzantine.

4.5.4 Nhận xét

Từ bảng so sánh, có thể thấy:

- DFD-IDS duy trì hiệu quả cạnh tranh trong môi trường lạnh tính, đồng thời tránh phụ thuộc vào việc tổng hợp trực tiếp trọng số mô hình như các phương pháp FL truyền thống.
- Trong các kịch bản PoisonedFL, phương pháp đề xuất thể hiện ưu thế rõ nhất khi tỉ lệ Byzantine ở mức 0.2, đặc biệt ở cấu hình đa kiến trúc nơi nhiều phương pháp so sánh gần như mất khả năng phân loại.
- Khi tỉ lệ Byzantine tăng lên 0.5, hiệu năng của Đề xuất suy giảm nhưng vẫn giữ được kết quả cao hơn các phương pháp bị sụp đổ hoàn toàn, cho thấy cơ chế lọc logits còn giữ được tín hiệu học hữu ích trong điều kiện tấn công mạnh.
- Bảng độ chính xác bộ lọc cho thấy Robust Logit Fusion phát hiện client độc hại ổn định hơn FedKD-IDS Hamming, đặc biệt trong kịch bản PoisonedFL tiêu chuẩn.

CHƯƠNG 5

Kết luận và hướng phát triển

5.1 Đánh giá kết quả thực tập

Sau 8 tuần thực tập tại Trung tâm An ninh mạng, nhóm tác giả đã đạt được những kết quả sau:

5.1.1 Kiến thức và kỹ năng đạt được

- **Về lý thuyết:** Nắm vững các kiến thức nền tảng về hệ thống phát hiện xâm nhập (IDS), học liên kết (Federated Learning), chất lọc kiến thức liên kết (Federated Distillation), các dạng tấn công độc hại trong môi trường liên kết (Byzantine attacks) và các cơ chế phòng thủ tương ứng.
- **Về thực hành:** Có khả năng triển khai và cấu hình môi trường thực nghiệm, tiền xử lý dữ liệu mạng, xây dựng và huấn luyện các mô hình học sâu sử dụng TensorFlow và PyTorch, đánh giá hiệu suất mô hình qua các chỉ số chuẩn.
- **Về kỹ năng mềm:** Phát triển kỹ năng làm việc nhóm, phân chia và quản lý công việc, kỹ năng thuyết trình và báo cáo kết quả nghiên cứu.

5.1.2 Sản phẩm đạt được

- Thiết kế và đề xuất DFD-IDS, một cơ chế học chất lọc liên kết phân tán cho phép nhiều kiến trúc mô hình cùng học liên kết, kết hợp thay thế mô hình discriminator bằng energy và có khả năng chống tấn công Byzantine hiệu quả trong quá trình tổng hợp mà vẫn giữ được kết quả phân loại xấp xỉ phương pháp State-of-the-art như SSFL-IDS ở kịch bản không tấn công.
- Bộ mã nguồn hiện thực trên nền tảng TensorFlow 2.11 và PyTorch 2.12.0.
- Kết quả thực nghiệm trên bộ dữ liệu CICIoT23 [?].
- Báo cáo thực tập tổng hợp các kết quả nghiên cứu và phát triển.

5.1.3 Hạn chế

Bên cạnh những kết quả đạt được, đề tài vẫn còn một số hạn chế:

- Cấu hình thực nghiệm còn thiếu đa dạng (về số lượng client và kiến trúc mô hình).
- Đánh giá mới chỉ tập trung vào một bộ dữ liệu CICIOT23, cần mở rộng sang nhiều bộ dữ liệu khác.
- Chưa xem xét các kịch bản tấn công kết hợp, khi các client Byzantine sử dụng nhiều tấn công khác nhau cùng lúc.

5.2 Kết luận

Nghiên cứu này đã đề xuất thành công DFD-IDS, một hệ thống học máy liên kết phát hiện xâm nhập, trong đó mang lại:

- **Model heterogeneity:** Sử dụng học chất lọc cho phép nhiều kiến trúc mô hình khác nhau tham gia học liên kết.
- **Decentralization:** Thiết kế phân tán giúp loại bỏ việc phụ thuộc vào một máy chủ cố định.
- **Lightweight discrimination:** Thay thế việc sử dụng một mô hình Discriminator tốn kém bằng cơ chế EVA có khả năng cấu hình ngưỡng đơn giản và ít tốn kém hơn.
- **Byzantine-robustness:** Có khả năng loại bỏ các client Byzantine khỏi quá trình tổng hợp với hiệu quả cao.

Kết quả thực nghiệm trên bộ dữ liệu CICIOT23 cho thấy độ chính xác 0.9415, xấp xỉ SSFL-IDS ở 0.9605 và FedAvg ở 0.9656, tuy nhiên ở kịch bản tấn công như PoisonedFL ở tỉ lệ 0.2, phương pháp có độ chính xác bền bỉ trước tấn công Byzantine là 0.9554 trong khi SSFL-IDS là 0.0061 và FedAvg là 0.0235, so với các phòng thủ khác là FLAME ở 0.7292 và FedKD-IDS ở 0.7173.

5.3 Hướng phát triển

Mặc dù DFD-IDS đã cho thấy những kết quả khả quan, vẫn còn một số hướng phát triển trong tương lai:

- **Triển khai trên môi trường thực tế:** Các thực nghiệm hiện tại được tiến hành trong môi trường mô phỏng. Nghiên cứu trong tương lai nên tập trung vào việc triển khai DFD-IDS trong môi trường mạng thực tế, bao gồm tích hợp với bộ điều khiển SDN và hệ thống SIEM.
- **Mở rộng quy mô:** Đánh giá giải pháp với số lượng clients lớn hơn (hàng trăm đến hàng nghìn) và các cấu trúc liên kết mạng đa dạng hơn.
- **Kết hợp học máy khả giải:** Tích hợp các kỹ thuật XAI (SHAP, LIME, GNNExplainer) để cung cấp các giải thích có thể diễn giải được cho các dự đoán IDS, hỗ trợ các nhà phân tích bảo mật trong việc hiểu và xác thực cảnh báo.
- **Cải thiện hiệu suất:** Tiếp tục cải thiện phương pháp để vượt SSFL-IDS trong điều kiện không có tấn công, nâng cao giá trị thực tiễn của phương pháp.

CHƯƠNG A

Bảng phân công công việc

Trong quá trình thực tập tại Trung tâm An ninh mạng, công việc theo từng tuần được mô tả như bảng sau

Bảng A.1: Phân công nhiệm vụ theo tuần

Tuần	Thành viên 1 (Tùng)	Thành viên 2 (Phúc)
1	Tìm hiểu tổng quan về Trung tâm, làm quen với môi trường và cơ sở hạ tầng kỹ thuật.	Tìm hiểu quy trình làm việc, các công cụ và hệ thống hiện có tại Trung tâm.
2	Nghiên cứu tổng quan về hệ thống IDS, phân loại, kiến trúc và các phương pháp phát hiện tấn công.	Nghiên cứu về Federated Learning: FedAvg, các thách thức Non-IID và client drift.
3	Nghiên cứu về Federated Distillation: FedMD, FedProto, SSFL-IDS, Cronus.	Nghiên cứu về Byzantine attacks: data poisoning, model poisoning, logit poisoning.
4	Nghiên cứu về Blom Robust Filter và các phương pháp robust aggregation (Krum, Median, TrimmedMean, FLAME, FLTrust).	Nghiên cứu về Energy-based OOD Detection và Evidential Knowledge Distillation.
5	Thiết kế kiến trúc tổng thể của DFD-IDS, triển khai cơ chế Energy-based Vote Abstention (EVA).	Triển khai Blom Spectral Filter và Robust Logit Fusion.
6	Triển khai cơ chế Decentralized Server Selection và tích hợp các module.	Triển khai Evidential Knowledge Distillation và tích hợp pipeline hoàn chỉnh.
7	Chuẩn bị môi trường thực nghiệm, tiền xử lý dữ liệu CICIoT23, xây dựng kịch bản thử nghiệm.	Tiến hành thực nghiệm, thu thập kết quả trên các kịch bản: benign và poisoning attacks.
Còn tiếp...		

Tuần	Thành viên 1 (Tùng)	Thành viên 2 (Phúc)
8	Phân tích kết quả, xây dựng bảng so sánh với các phương pháp baseline, viết báo cáo tổng kết.	Hoàn thiện báo cáo, vẽ biểu đồ, kiểm tra lỗi và chuẩn bị tài liệu trình bày.

Tài liệu tham khảo

- [1] Durmus Alp Emre Acar, Yue Zhao, Ramon Matas Navarro, Matthew Mattina, Paul N Whatmough, and Venkatesh Saligrama. Federated learning based on dynamic regularization. *arXiv preprint arXiv:2111.04263*, 2021.
- [2] Gilad Baruch, Moran Baruch, and Yoav Goldberg. A little is enough: Circumventing defenses for distributed learning. *Advances in Neural Information Processing Systems*, 32, 2019.
- [3] Enrique Tomás Martínez Beltrán, Mario Quiles Pérez, Pedro Miguel Sánchez Sánchez, Sergio López Bernal, Gérôme Bovet, Manuel Gil Pérez, Gregorio Martínez Pérez, and Alberto Huertas Celdrán. Decentralized federated learning: Fundamentals, state of the art, frameworks, trends, and challenges. *IEEE Communications Surveys & Tutorials*, 25(4):2983–3013, 2023.
- [4] Peva Blanchard, El Mahdi El Mhamdi, Rachid Guerraoui, and Julien Stainer. Machine learning with adversaries: Byzantine tolerant gradient descent. *Advances in neural information processing systems*, 30, 2017.
- [5] Gunnar Blom. *Statistical Estimates and Transformed Beta-Variables*. Almqvist & Wiksell, Stockholm, 1958.
- [6] Keith Bonawitz, Vladimir Ivanov, Ben Kreuter, Antonio Marcedone, H Brendan McMahan, Sarvar Patel, Daniel Ramage, Aaron Segal, and Karn Seth. Practical secure aggregation for federated learning on user-held data. *arXiv preprint arXiv:1611.04482*, 2016.
- [7] Xiaoyu Cao, Minghong Fang, Jia Liu, and Neil Zhenqiang Gong. Fltrust: Byzantine-robust federated learning via trust bootstrapping. *arXiv preprint arXiv:2012.13995*, 2020.
- [8] Hongyan Chang, Virat Shejwalkar, Reza Shokri, and Amir Houmansadr. Cronus: Robust and heterogeneous collaborative learning with black-box knowledge transfer. *arXiv preprint arXiv:1912.11279*, 2019.
- [9] Ilias Diakonikolas, Gautam Kamath, Daniel M Kane, Jerry Li, Ankur Moitra, and

- Alistair Stewart. Being robust (in high dimensions) can be practical. In *International Conference on Machine Learning*, pages 999–1008. PMLR, 2017.
- [10] Minghong Fang, Xiaoyu Cao, Jinyuan Jia, and Neil Gong. Local model poisoning attacks to {Byzantine-Robust} federated learning. In *29th USENIX security symposium (USENIX Security 20)*, pages 1605–1622, 2020.
- [11] Othmane Friha, Mohamed Amine Ferrag, Mohamed Benbouzid, Tarek Berghout, Burak Kantarci, and Kim-Kwang Raymond Choo. 2df-ids: Decentralized and differentially private federated learning-based intrusion detection system for industrial iot. *Computers & Security*, 127:103097, 2023.
- [12] Karan Ganju, Qi Wang, Wei Yang, Carl A Gunter, and Nikita Borisov. Property inference attacks on fully connected neural networks using permutation invariant representations. In *Proceedings of the 2018 ACM SIGSAC conference on computer and communications security*, pages 619–633, 2018.
- [13] Jonas Geiping, Hartmut Bauermeister, Hannah Dröge, and Michael Moeller. Inverting gradients-how easy is it to break privacy in federated learning? *Advances in neural information processing systems*, 33:16937–16947, 2020.
- [14] Rachid Guerraoui, Sébastien Rouault, et al. The hidden vulnerability of distributed learning in byzantium. In *International conference on machine learning*, pages 3521–3530. PMLR, 2018.
- [15] Yuting He, Yiqiang Chen, XiaoDong Yang, Hanchao Yu, Yi-Hua Huang, and Yang Gu. Learning critically: Selective self-distillation in federated learning on non-iid data. *IEEE Transactions on Big Data*, 10(6):789–800, 2022.
- [16] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- [17] Vanlalruata Hnamte and Jamal Hussain. Dcnnbilstm: An efficient hybrid deep learning-based intrusion detection system. *Telematics and Informatics Reports*, 10:100053, 2023.
- [18] Eunjeong Jeong, Seungeun Oh, Hyesung Kim, Jihong Park, Mehdi Bennis, and Seong-Lyun Kim. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data. *arXiv preprint arXiv:1811.11479*, 2018.
- [19] Sydney Mambwe Kasongo. A deep learning technique for intrusion detection system using a recurrent neural networks based framework. *Computer Communications*, 199:113–125, 2023.

- [20] Jinkyu Kim, Geeho Kim, and Bohyung Han. Multi-level branched regularization for federated learning. In *International Conference on Machine Learning*, pages 11058–11073. PMLR, 2022.
- [21] Beibei Li, Yuhao Wu, Jiarui Song, Rongxing Lu, Tao Li, and Liang Zhao. Deepfed: Federated deep learning for intrusion detection in industrial cyber-physical systems. *IEEE Transactions on Industrial Informatics*, 17(8):5615–5624, 2020.
- [22] Daliang Li and Junpu Wang. Fedmd: Heterogenous federated learning via model distillation. *arXiv preprint arXiv:1910.03581*, 2019.
- [23] Lin Li, Jianping Gou, Baosheng Yu, Lan Du, and Zhang Yiand Dacheng Tao. Federated distillation: A survey. *arXiv preprint arXiv:2404.08564*, 2024.
- [24] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, and Virginia Smith. Federated optimization in heterogeneous networks. *Proceedings of Machine learning and systems*, 2:429–450, 2020.
- [25] Weitang Liu, Xiaoyun Wang, John Owens, and Yixuan Li. Energy-based out-of-distribution detection. *Advances in neural information processing systems*, 33:21464–21475, 2020.
- [26] Leland McInnes, John Healy, Steve Astels, et al. hdbscan: Hierarchical density based clustering. *J. Open Source Softw.*, 2(11):205, 2017.
- [27] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Artificial intelligence and statistics*, pages 1273–1282. Pmlr, 2017.
- [28] Luca Melis, Congzheng Song, Emiliano De Cristofaro, and Vitaly Shmatikov. Exploiting unintended feature leakage in collaborative learning. In *2019 IEEE symposium on security and privacy (SP)*, pages 691–706. IEEE, 2019.
- [29] Mert Nakip, Baran Can Gül, and Erol Gelenbe. Decentralized online federated g-network learning for lightweight intrusion detection. In *2023 31st international symposium on modeling, analysis, and simulation of computer and telecommunication systems (MASCOTS)*, pages 1–8. IEEE, 2023.
- [30] NETGEAR. The 2024 iot security landscape report. <https://www.netgear.com/hub/network/2024-iot-threat-report/>, 2024. Accessed 2026-06-06.
- [31] Euclides Carlos Pinto Neto, Sajjad Dadkhah, Raphael Ferreira, Alireza Zohourian, Rongxing Lu, and Ali A Ghorbani. Ciciot2023: A real-time dataset and benchmark for large-scale attacks in iot environment. *Sensors*, 23(13):5941, 2023.

- [32] Euclides Carlos Pinto Neto, Sajjad Dadkhah, Raphael Ferreira, Alireza Zohourian, Rongxing Lu, and Ali A Ghorbani. Ciciot2023: A real-time dataset and benchmark for large-scale attacks in iot environment. *Sensors*, 23(13):5941, 2023.
- [33] Thien Duc Nguyen, Phillip Rieger, Huili Chen, Hossein Yalame, Helen Möllering, Hossein Fereidooni, Samuel Marchal, Markus Miettinen, Azalia Mirhoseini, Shaza Zeitouni, et al. {FLAME}: Taming backdoors in federated learning. In *31st USENIX security symposium (USENIX Security 22)*, pages 1415–1432, 2022.
- [34] Apostolos Pyrgelis, Carmela Troncoso, and Emiliano De Cristofaro. Knock knock, who’s there? membership inference on aggregate location data. *arXiv preprint arXiv:1708.06145*, 2017.
- [35] Christophe Roux, Max Zimmer, and Sebastian Pokutta. On the byzantine-resilience of distillation-based federated learning. In *International Conference on Learning Representations*, volume 2025, pages 43105–43130, 2025.
- [36] Abhijit Guha Roy, Shayan Siddiqui, Sebastian Pölsterl, Nassir Navab, and Christian Wachinger. Braintorrent: A peer-to-peer environment for decentralized federated learning. *arXiv preprint arXiv:1905.06731*, 2019.
- [37] SonicWall. 2024 mid-year cyber threat report. <https://www.tdsynnex.com/na/us/cybersolv/wp-content/uploads/sites/10/2024/11/SonicWall-2024-Mid-Year-Cyber-Threat-Report.pdf>, 2024. Accessed 2026-06-06.
- [38] Yue Tan, Guodong Long, Lu Liu, Tianyi Zhou, Qinghua Lu, Jing Jiang, and Chengqi Zhang. Fedproto: Federated prototype learning across heterogeneous clients. In *Proceedings of the AAAI conference on artificial intelligence*, volume 36, pages 8432–8440, 2022.
- [39] The Hacker News. Doj disrupts 3 million-device iot botnets behind record 31.4 tbps ddos attacks. <https://thehackernews.com/2026/03/doj-disrupts-3-million-device-iot.html>, 2026. Accessed 2026-06-06.
- [40] Vale Tolpegin, Stacey Truex, Mehmet Emre Gursoy, and Ling Liu. Data poisoning attacks against federated learning systems. In *European symposium on research in computer security*, pages 480–501. Springer, 2020.
- [41] Liangyu Xiang, Junyu Gao, and Changsheng Xu. Evidential knowledge distillation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 2814–2824, 2025.
- [42] Yueqi Xie, Minghong Fang, and Neil Zhenqiang Gong. Model poisoning attacks to federated learning via multi-round consistency. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 15454–15463, 2025.

- [43] Dong Yin, Yudong Chen, Ramchandran Kannan, and Peter Bartlett. Byzantine-robust distributed learning: Towards optimal statistical rates. In *International conference on machine learning*, pages 5650–5659. Pmlr, 2018.
- [44] Bo Zhao, Konda Reddy Mopuri, and Hakan Bilen. idlg: Improved deep leakage from gradients. *arXiv preprint arXiv:2001.02610*, 2020.
- [45] Ruijie Zhao, Yijun Wang, Zhi Xue, Tomoaki Ohtsuki, Bamidele Adebisi, and Guan Gui. Semisupervised federated-learning-based intrusion detection method for internet of things. *IEEE Internet of Things Journal*, 10(10):8645–8657, 2022.
- [46] Ligeng Zhu, Zhijian Liu, and Song Han. Deep leakage from gradients. *Advances in neural information processing systems*, 32, 2019.